

# **Introdução ao Anaconda, Jupyter Notebook e Python**

Do conceito à instalação e manipulação

---

# Quem Sou Eu

---

Uma breve descrição

---

# APRESENTAÇÃO



**Mateus Rocha**

**Técnico em Informática**

**IFPB - 2019**

**Estatístico**

**UEPB - 2024**

**Cientista de Dados e Professor**

**ASN-Rocks - Atualmente**

# Ambiente de Desenvolvimento

---

Dos editores de texto até o Anaconda

---

# ONDE ESCREVER CÓDIGO?

Programar não é apenas escrever texto; é estabelecer uma comunicação entre a sua ideia e o processador do computador. **O ambiente de desenvolvimento serve como o tradutor e o espaço de trabalho nessa conversa.**

**O Código é a Receita:** Você pode escrevê-lo em qualquer lugar (até num guardanapo/Bloco de Notas).

**O Ambiente é a Cozinha:** Ele oferece o fogão (o motor que executa o código), os utensílios (ferramentas de correção) e a bancada organizada (onde você visualiza os arquivos).

# IDE (Integrated Development Environment)

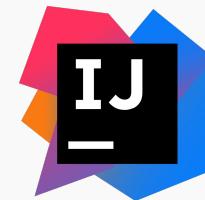
As IDEs são ambientes completos, como uma "oficina mecânica" cheia de ferramentas avançadas. Elas não servem apenas para escrever texto, mas oferecem tudo o que é necessário para grandes projetos.

## Características

Possuem preenchimento automático de código (IntelliSense), ferramentas de depuração (debug) para encontrar erros, e integração com bancos de dados.

## Exemplos

PyCharm (específica para Python), IntelliJ IDEA (muito usada para Java) e Visual Studio (completo para C# e C++).



# EDITORES DE CÓDIGO

São muito mais rápidos e leves que uma IDE, mas dependem da instalação de extensões (plugins) para ganhar poderes.

## Características

Focam na velocidade e na versatilidade. Você pode usar o mesmo editor para Python, HTML, CSS ou JavaScript apenas mudando a configuração.

## Exemplos

VS Code (Visual Studio Code) – o mais popular atualmente – e o Sublime Text, notepad ++.



# JUPYTER NOTEBOOK

O Jupyter é um ambiente de desenvolvimento interativo que funciona no navegador. Ele rompe com o modelo tradicional de "escrever um arquivo de texto longo e rodar tudo de uma vez", permitindo que você execute o código em pedaços (células).

## Características

Permitem a mistura de código vivo, equações, textos explicativos e visualizações ricas (gráficos e tabelas). Sua grande vantagem é a execução modular, onde você não precisa rodar o projeto inteiro para testar apenas uma pequena alteração.

## Exemplos

Jupyter Notebook (local, via Anaconda), Google Colab (versão em nuvem do Google) e Kaggle Kernels.



# O QUE É O ANACONDA?



O Anaconda é a principal distribuição científica da linguagem Python. Ele organiza onde cada ferramenta fica, garante que elas tenham o que precisam para funcionar e evita conflitos entre elas.

## Plataforma "Tudo-em-Um"

Ao instalar o Anaconda, você já recebe o Python, o Jupyter Notebook, o Spyder e as principais bibliotecas de ciência de dados pré-configuradas.

## Gestão de Ambientes (Conda)

Permite criar "bolhas" isoladas para cada projeto. Você pode ter um projeto de Machine Learning usando uma versão X de uma biblioteca e outro projeto usando a versão Y, sem que um interfira no outro.

# Baixando as Ferramentas

---

Entendendo como manipular o Anaconda e o Jupyter Notebook

---

# COMO BAIXAR?



Primeiramente Acesse o site: <https://www.anaconda.com/download>

The screenshot shows the Anaconda website homepage. At the top, there's a navigation bar with the Anaconda logo, menu items for Products, Solutions, Resources, and Company, and buttons for Sign In and Get Demo. Below the navigation, there's a large section titled "Get Started with Anaconda - Free" which includes a brief description of what's included in the distribution and links for "What's included in Anaconda Distribution?", "What's included in my free Anaconda account?", and "Added Benefits for Academic Institutions". To the right of this, there's a prominent "Download Now" button with the subtext "Get access in 30 seconds. Completely free.\*" and two links: "Get Started >" and "Returning Users >". Below this, there's a small note about terms and conditions. At the bottom of the page, there's a section titled "Manage Trusted Packages and Environments with Ease" with the subtext "Spend more time developing and less time managing package updates and dependencies".

# COMO BAIXAR?



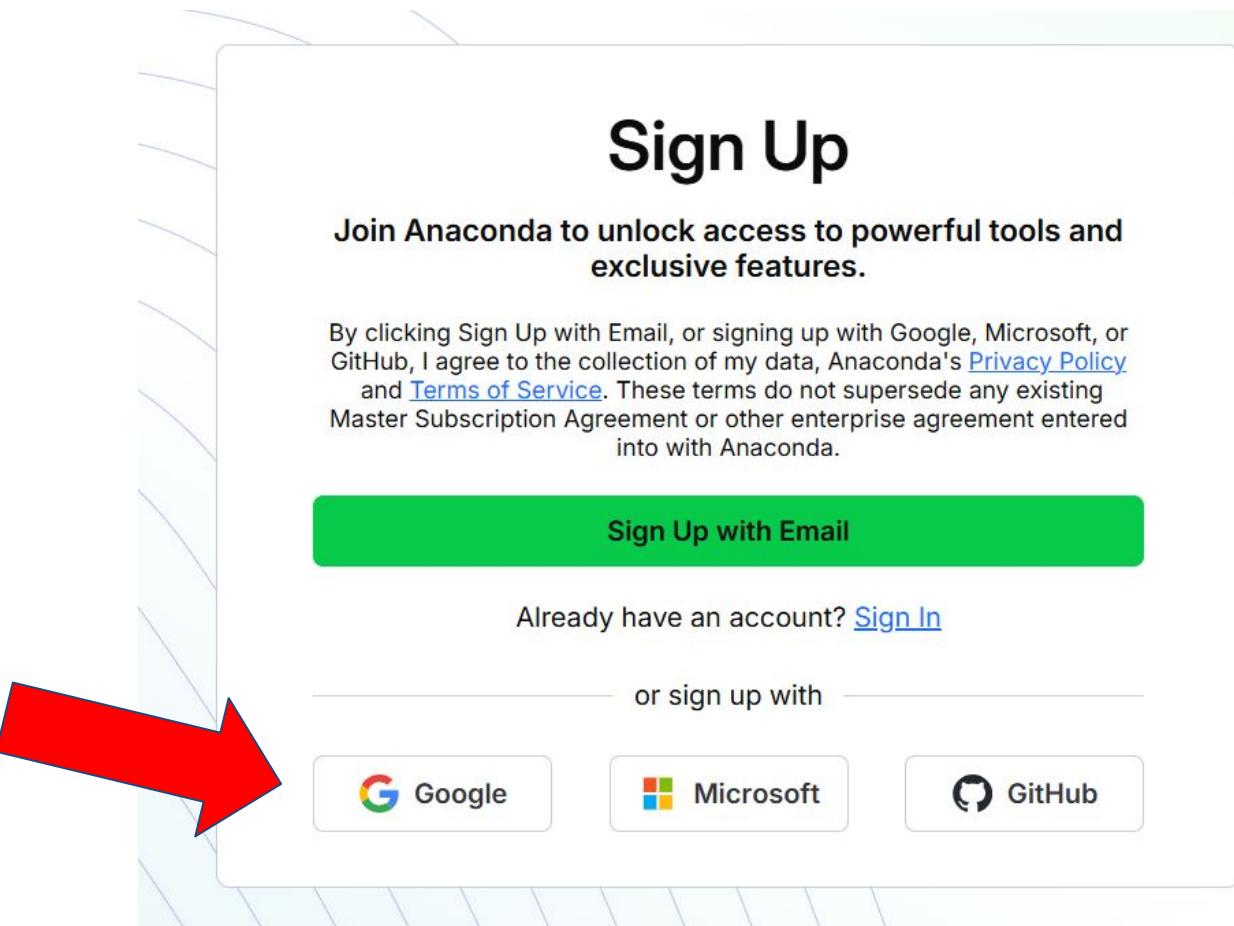
Clique em Get Started:

The screenshot shows the Anaconda website's "Get Started with Anaconda - Free" page. At the top, there is a navigation bar with links for Products, Solutions, Resources, and Company, along with Sign In and Get Demo buttons. Below the navigation, there is a section titled "Get Started with Anaconda - Free" which includes a brief description of the product and three expandable sections: "What's included in Anaconda Distribution?", "What's included in my free Anaconda account?", and "Added Benefits for Academic Institutions". To the right of this section is a "Download Now" box with a green "Get Started" button highlighted by a large red arrow. The box also contains text about getting access in 30 seconds and being completely free, along with links for "Returning Users" and terms and conditions. Below this box is a large call-to-action section with the heading "Manage Trusted Packages and Environments with Ease" and a subtext "Spend more time developing and less time managing package updates and dependencies".

# COMO BAIXAR?

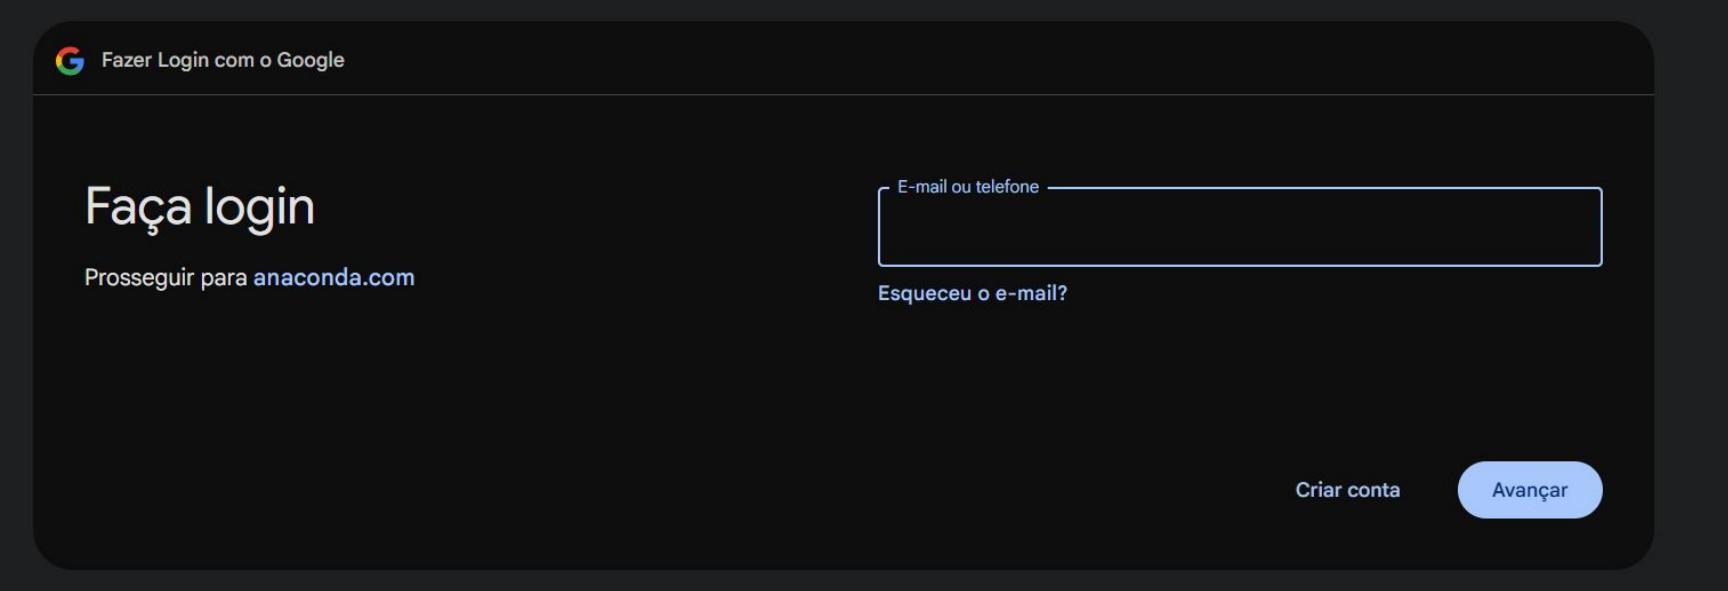


Você precisará de uma conta para baixar o ANACONDA, vamos clicar no Google por exemplo



# COMO BAIXAR?

Faça o login com a sua conta **Google**:



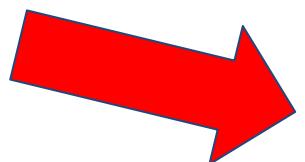
A screenshot of a Google sign-in interface. At the top left is the Google 'G' logo and the text 'Fazer Login com o Google'. Below this, the heading 'Faça login' is displayed. Underneath it, there is a link 'Prosseguir para anaconda.com'. To the right of the heading is a large input field labeled 'E-mail ou telefone' with a placeholder 'Digite seu e-mail'. Below this input field is a link 'Esqueceu o e-mail?'. At the bottom right of the interface are two buttons: 'Criar conta' and a blue rounded rectangle button labeled 'Avançar'.

# COMO BAIXAR?



Primeiro escolha o sistema operacional e depois baixe o **Anaconda Distribution**

## Choose Your Download

[Windows](#)[Mac](#)[Linux](#)

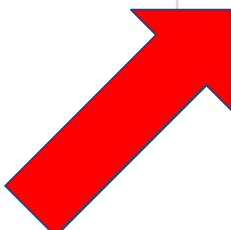
### Anaconda Distribution

Complete package with 8,000+ libraries, Jupyter, JupyterLab, and Spyder IDE. Everything you need for data science.

[Windows 64-Bit Graphical Installer](#)

### Miniconda

Minimal installer with just Python, Conda, and essential dependencies. Install only what you need.

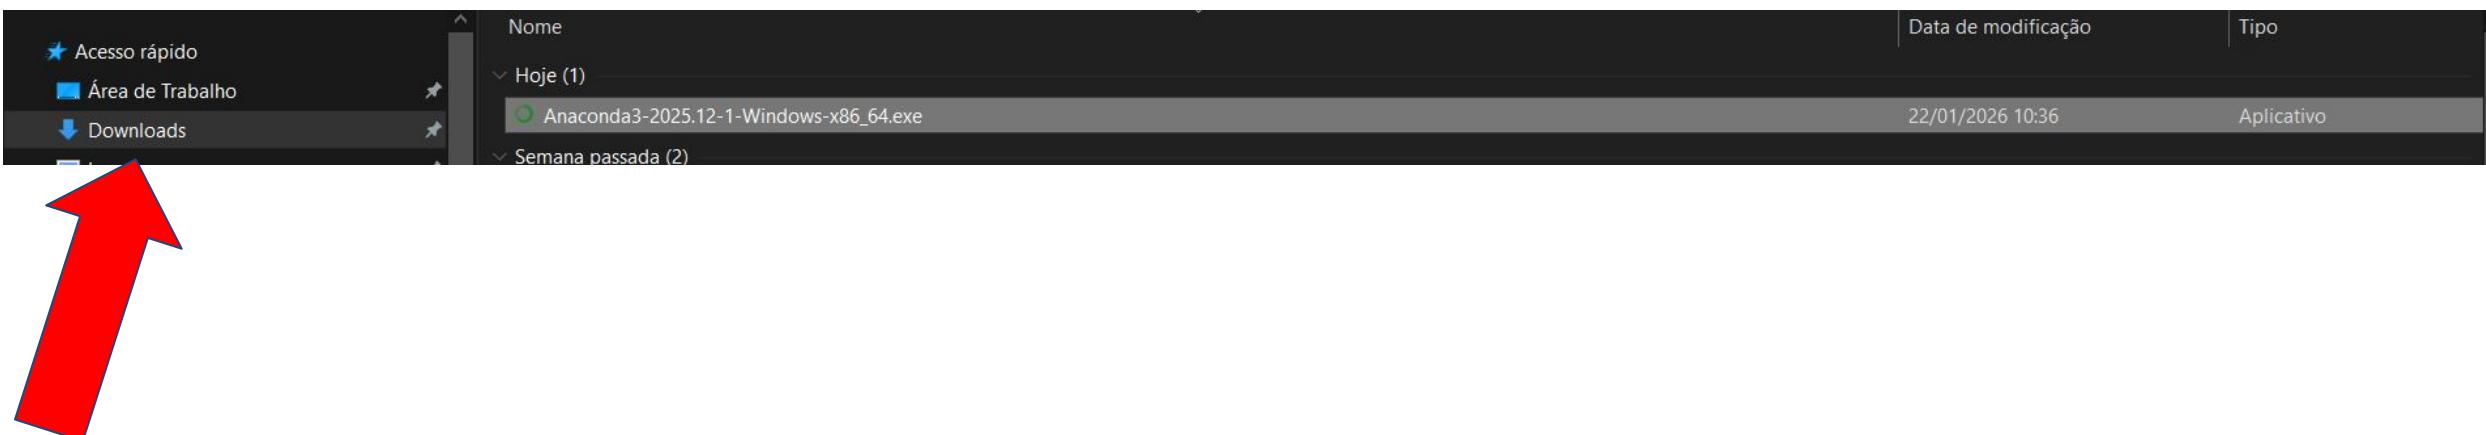
[Windows 64-Bit Graphical Installer](#)

# COMO BAIXAR?



Vá na aba de Download do seu computador e clique no instalador

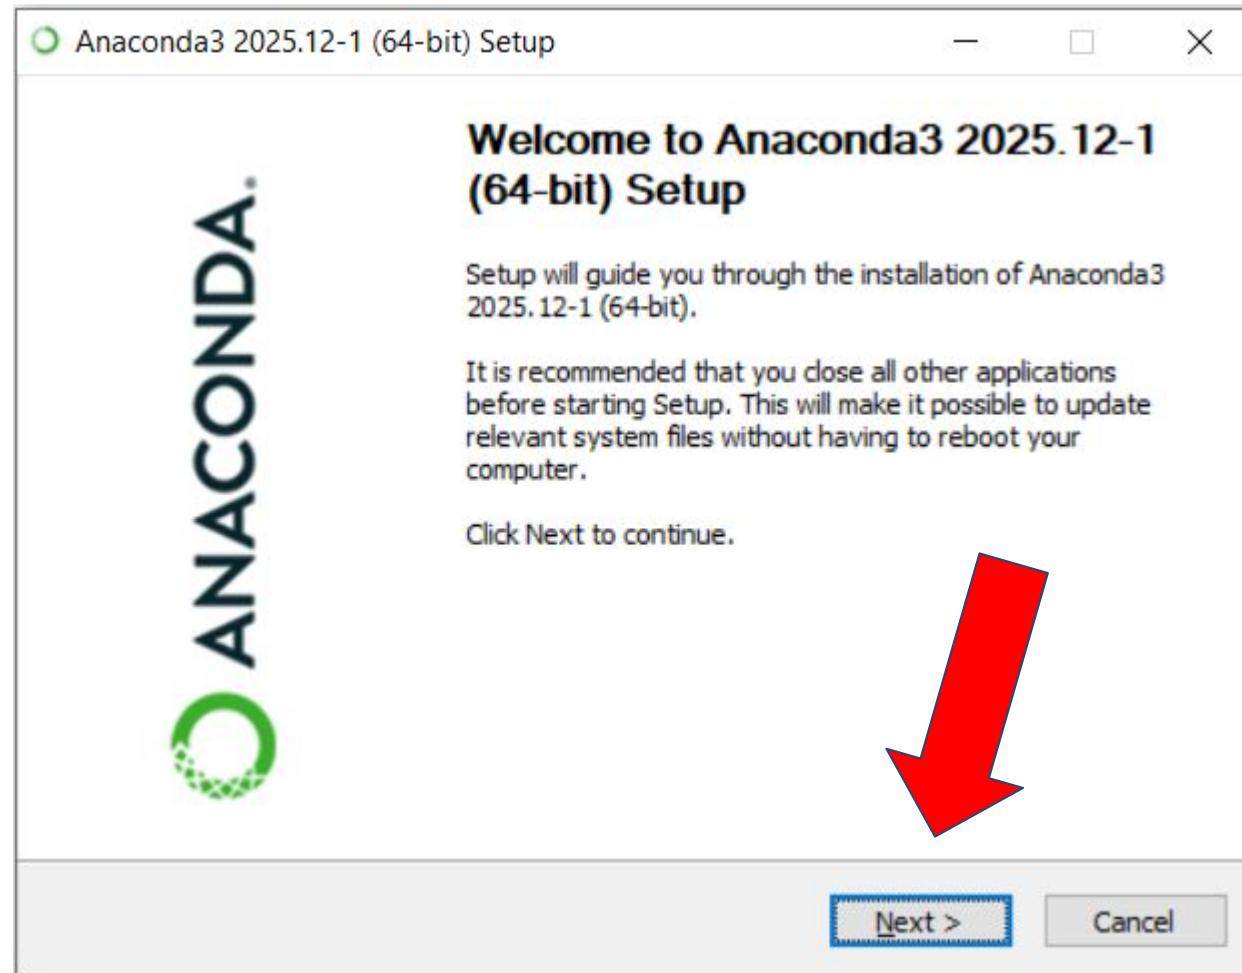
**Anaconda3-2025.12-1-Windows-x86\_64.exe**



# COMO BAIXAR?



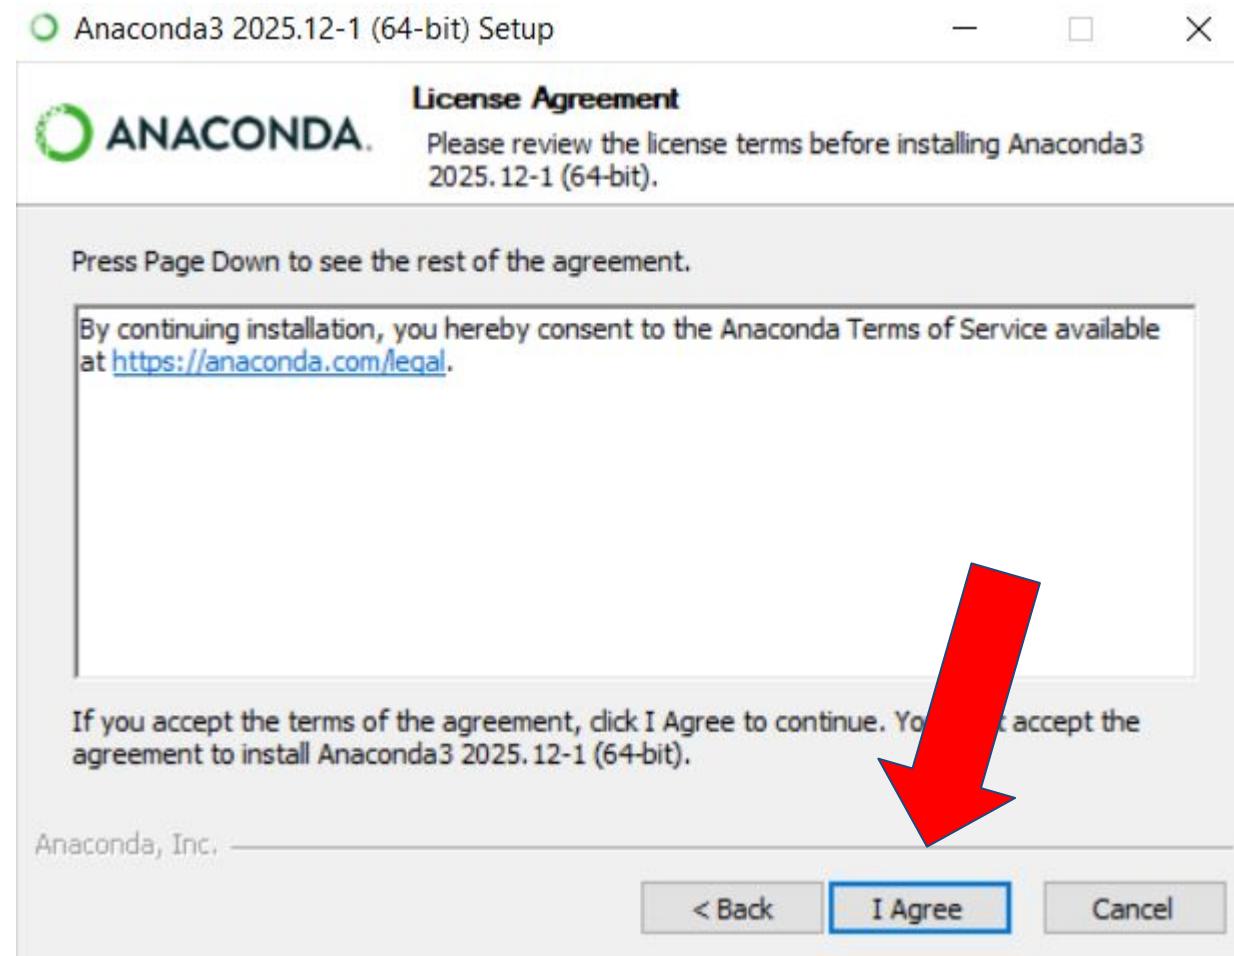
Clique em **next**



# COMO BAIXAR?

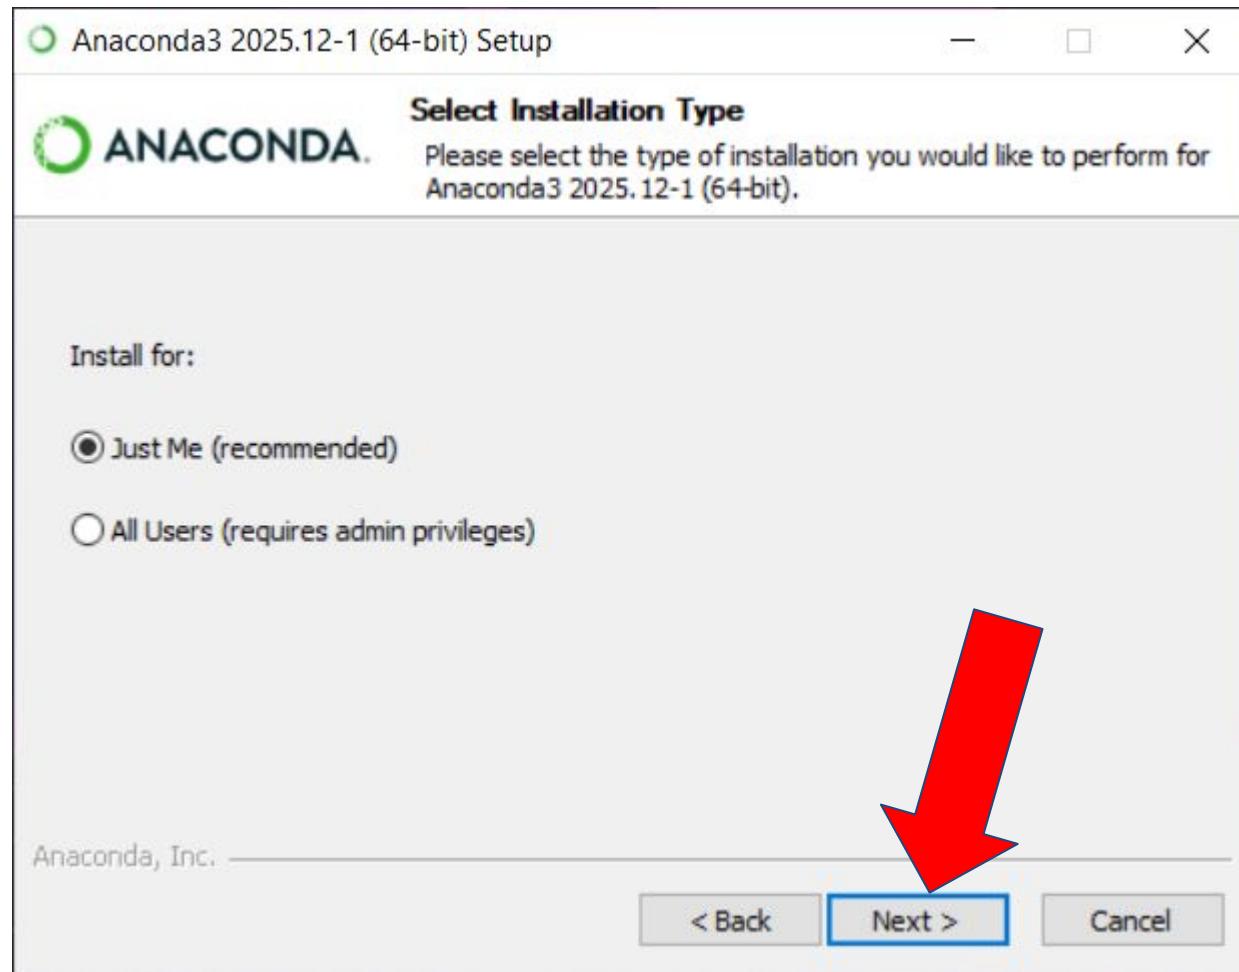


Clique em I Agree



# COMO BAIXAR?

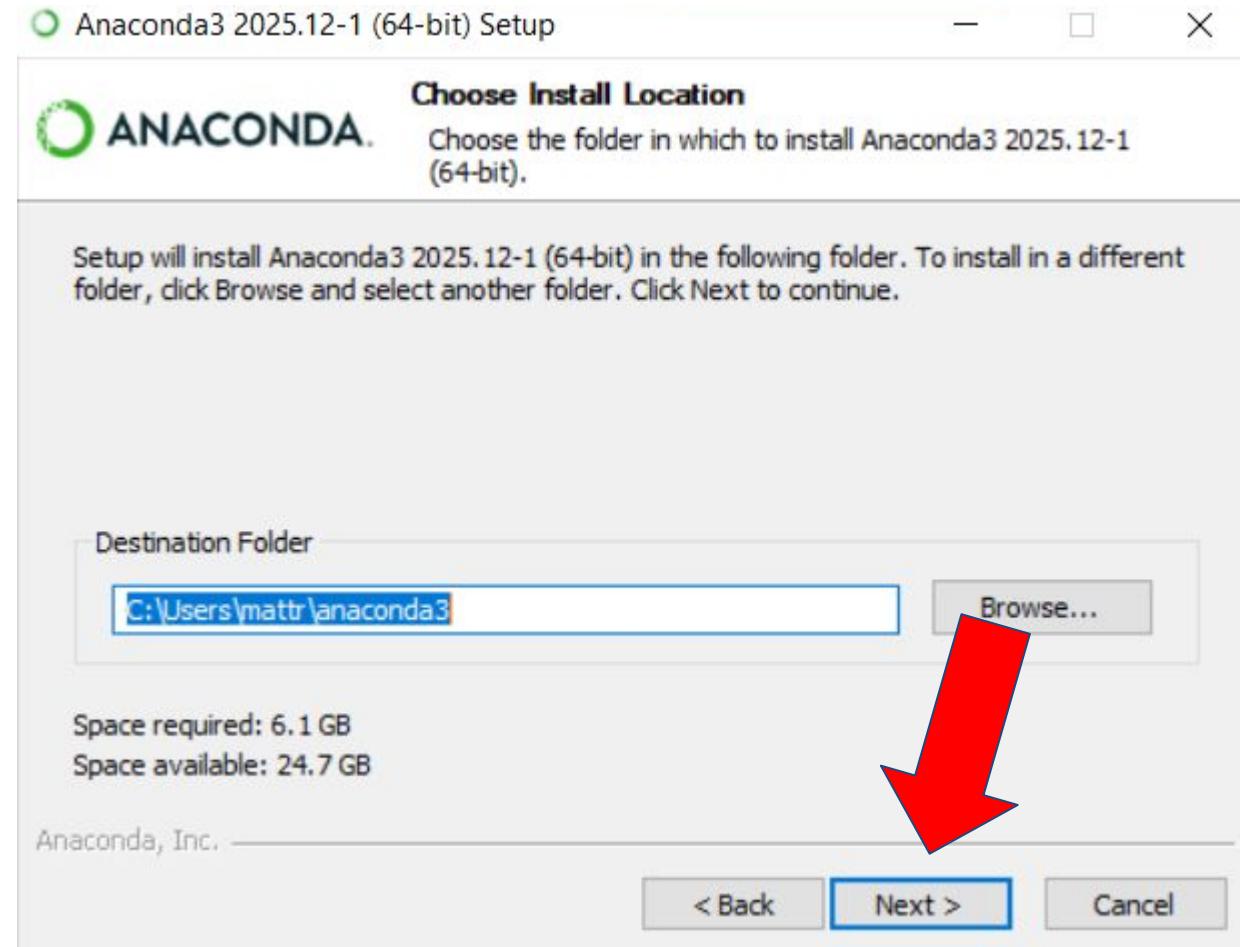
Deixe a opção **Just Me** e clique em **Next**



# COMO BAIXAR?



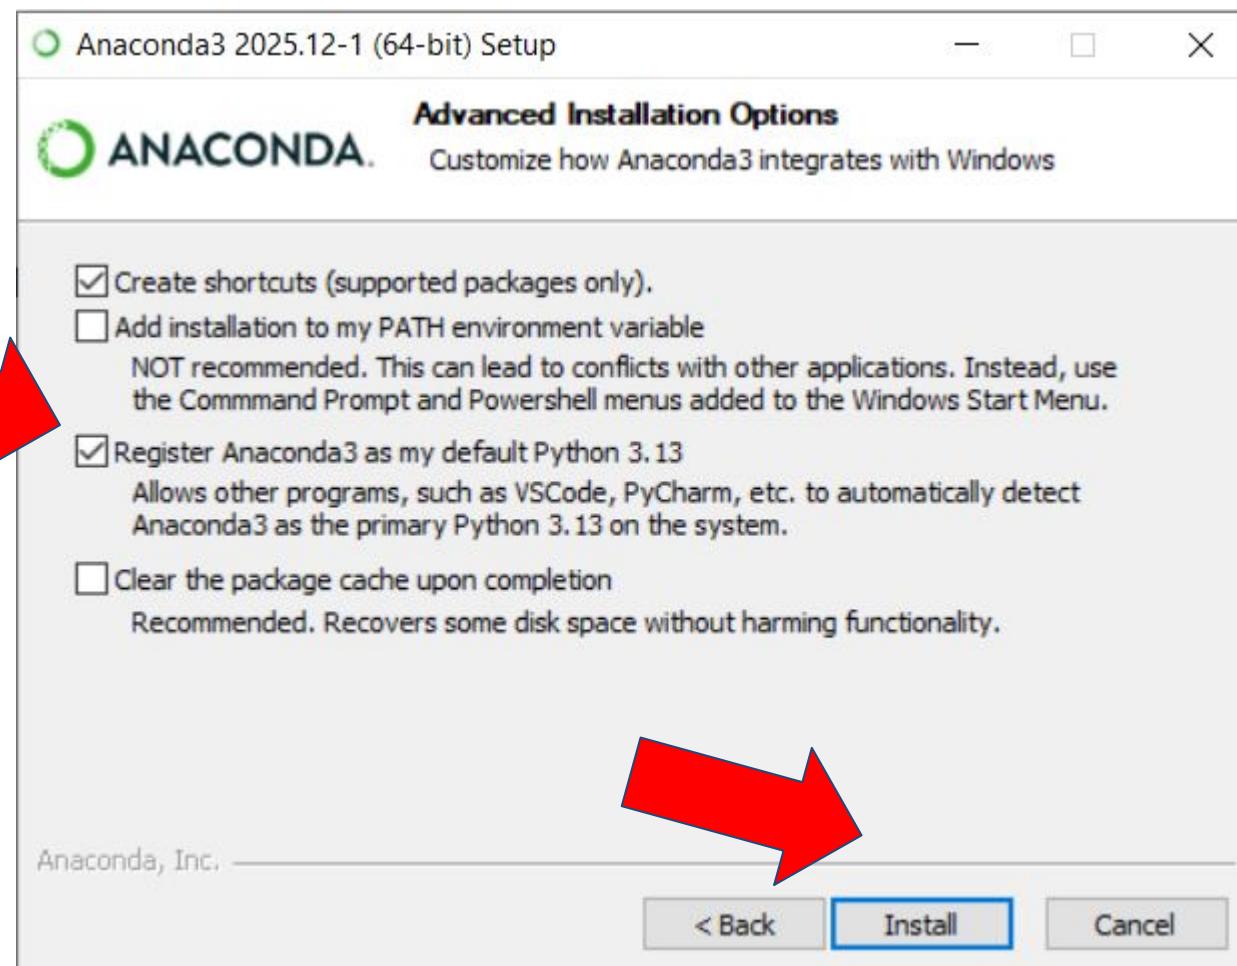
Deixe a opção padrão do diretório de destino onde o Anaconda ficará e clique em **Next**



# COMO BAIXAR?



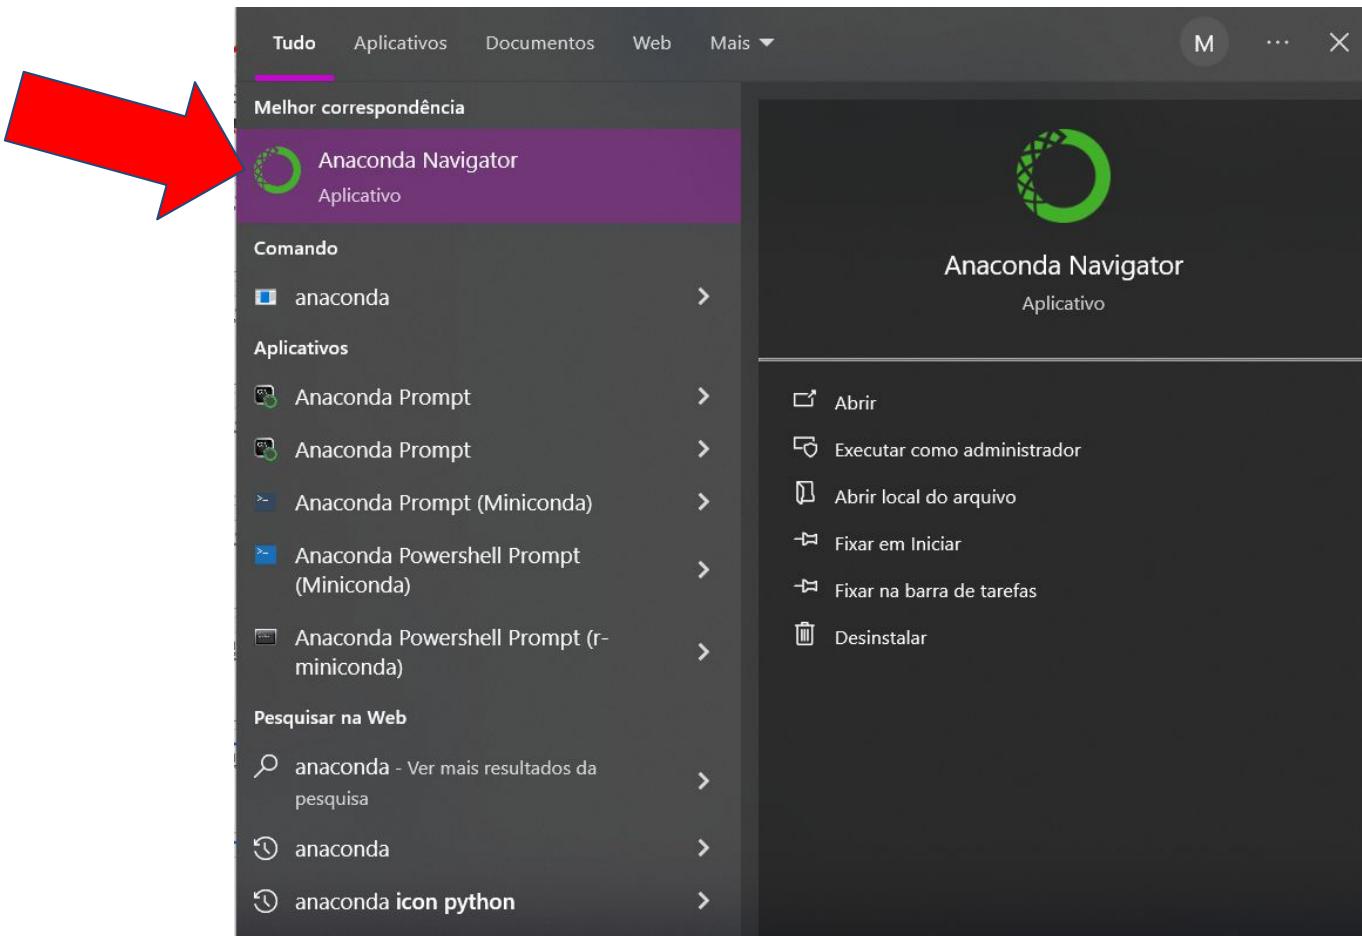
Clique na opção **Register Anaconda3 as my default Python 3.13** e depois em **Install**. Após isso basta aguardar.



# COMO ABRIR O ANACONDA?



Pesquise Anaconda na aba de pesquisa de aplicativos do seu sistema operacional e clique em Anaconda Navigator



# COMO ABRIR O JUPYTER NOTEBOOK?



É necessário instalar o jupyter notebook, clique em **Install**

The screenshot shows the Anaconda Navigator interface. On the left is a sidebar with links for Home, Environments, Learning, and Community. Below that is a section for 'Anaconda Quick Start Environments' with a 'Launch Your Environment' button. At the bottom are social media icons for X, GitHub, YouTube, and LinkedIn. The main area is titled 'ANACONDA.NAVIGATOR' and displays a grid of application cards. One card for 'JupyterLab' is highlighted with a large red arrow pointing to its 'Install' button. Other cards include PyCharm, Anaconda AI Navigator, Anaconda Toolbox, Anaconda Cloud Notebooks, anaconda\_powershell\_prompt, anaconda\_prompt, JupyterLab, Notebook, Qt Console, Spyder, VS Code, EduBlocks, WatsonX, Oracle Cloud Infrastructure, PyScript, PythonAnywhere, CMD.exe Prompt, and console\_shortcut\_miniconda. Each card includes a small icon, the application name, a version number, a brief description, and either 'Install' or 'Launch' buttons.

# COMO ABRIR O JUPYTER NOTEBOOK?



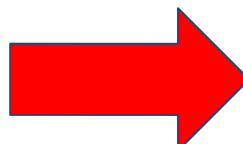
Depois clique em **Launch**, ele abrirá no seu navegador padrão ou pedirá para você selecionar um navegador para abrir.

The screenshot shows the Anaconda Navigator interface. On the left is a sidebar with links for Home, Environments, Learning, and Community. Below that is a section for 'Anaconda Quick Start Environments' with a 'Launch Your Environment' button. At the bottom are social media icons for X, GitHub, YouTube, and LinkedIn. The main area is titled 'ANACONDA.NAVIGATOR' and displays a grid of application cards. One card for 'JupyterLab' is highlighted with a large red arrow pointing to its 'Launch' button. Other cards include PyCharm, Anaconda AI Navigator, Anaconda Toolbox, Anaconda Cloud Notebooks, anaconda\_powershell\_prompt, anaconda\_prompt, JupyterLab, Notebook, Qt Console, Spyder, VS Code, EduBlocks, WatsonX, Oracle Cloud Infrastructure, PyScript, PythonAnywhere, CMD.exe Prompt, and console\_shortcut\_miniconda. Each card includes a small icon, the application name, a version number, a brief description, and either an 'Install' or 'Launch' button.

# COMO USAR O JUPYTER NOTEBOOK?



Essa é o início do Jupyter Notebook. Aqui são os diretórios (pastas) do seu computador



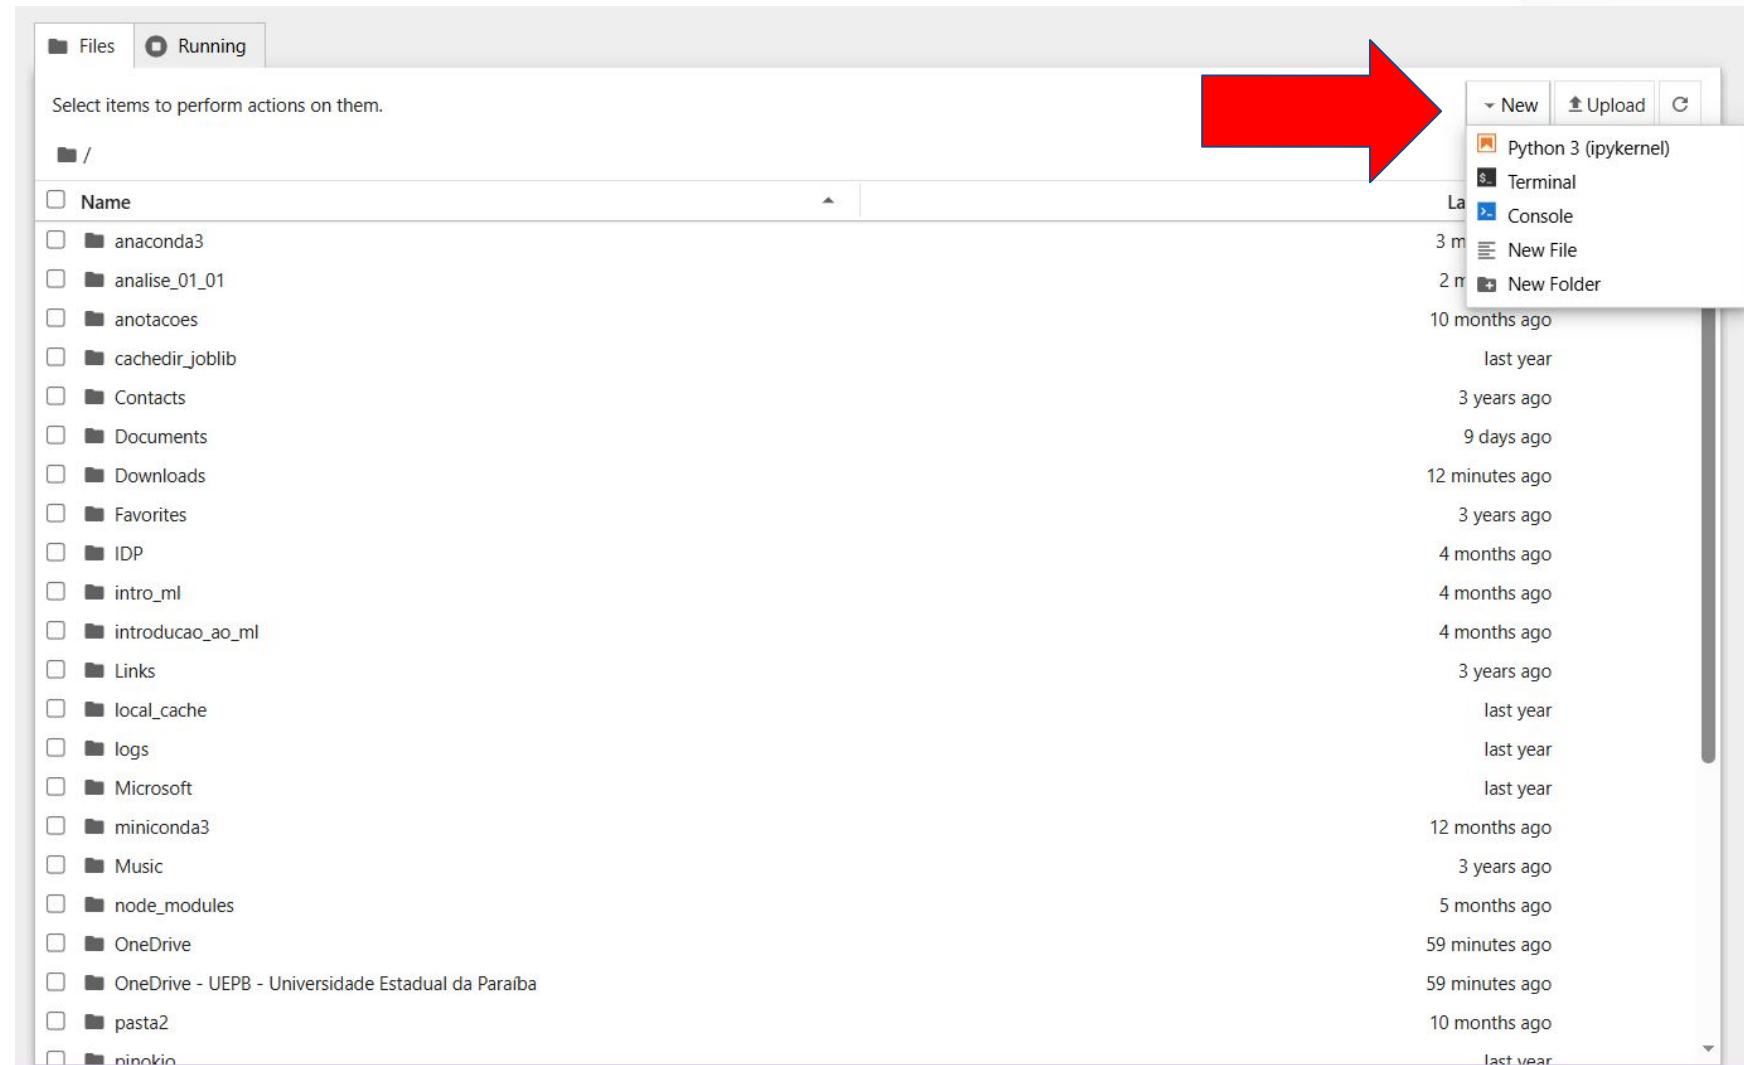
The screenshot shows the Jupyter Notebook interface with a file browser window. The window title is "jupyter" and the tab selected is "Files". The main area displays a list of directories and files in the root directory. A red box highlights the entire list area. A red arrow points to the left edge of the browser window, likely indicating where to click to start interacting with the files.

Name	Last Modified	File Size
anaconda3	39 seconds ago	
analise_01_01	2 months ago	
anotacoes	10 months ago	
cacheder_joblib	last year	
Contacts	3 years ago	
Documents	9 days ago	
Downloads	9 minutes ago	
Favorites	3 years ago	
IDP	4 months ago	
intro_ml	4 months ago	
introducao_ao_ml	4 months ago	
Links	3 years ago	
local_cache	last year	
logs	last year	
Microsoft	last year	
miniconda3	12 months ago	
Music	3 years ago	
node_modules	5 months ago	
OneDrive	56 minutes ago	
OneDrive - UEPB - Universidade Estadual da Paraíba	56 minutes ago	
pasta2	10 months ago	

# COMO USAR O JUPYTER NOTEBOOK?



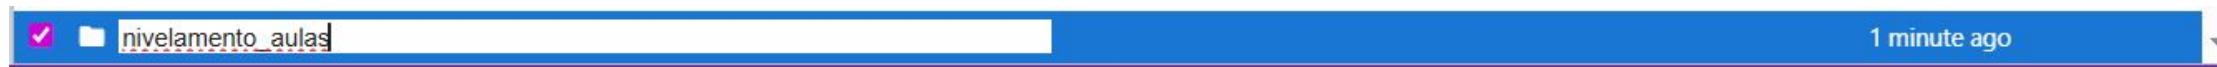
Clique em New e depois em New Folder



# COMO USAR O JUPYTER NOTEBOOK?



No final dos diretórios, ele **criará um novo diretório para você**. Vamos renomear para **nivelamento\_aulas**



# COMO USAR O JUPYTER NOTEBOOK?



Dê dois cliques na nova pasta criada para entrar nela.

A screenshot of a file explorer window showing a list of files and folders. The columns are labeled 'Name', 'Last Modified', and 'File Size'. A red arrow points to the folder 'nivelamento\_aulas', which is highlighted with a blue selection bar. The folder 'nivelamento\_aulas' was created 1 minute ago. Other visible folders include 'Documents', 'Downloads', 'Favorites', 'IDP', 'intro\_ml', 'introducao\_ao\_ml', 'Links', 'local\_cache', 'logs', 'Microsoft', 'miniconda3', 'Music', 'node\_modules', 'OneDrive', 'OneDrive - UEPB - Universidade Estadual da Paraíba', 'pasta2', 'pinokio', 'Saved Games', 'Searches', 'tensorflow\_datasets', and 'testes'. The 'Last Modified' column shows various dates from '14 minutes ago' to '3 years ago'.

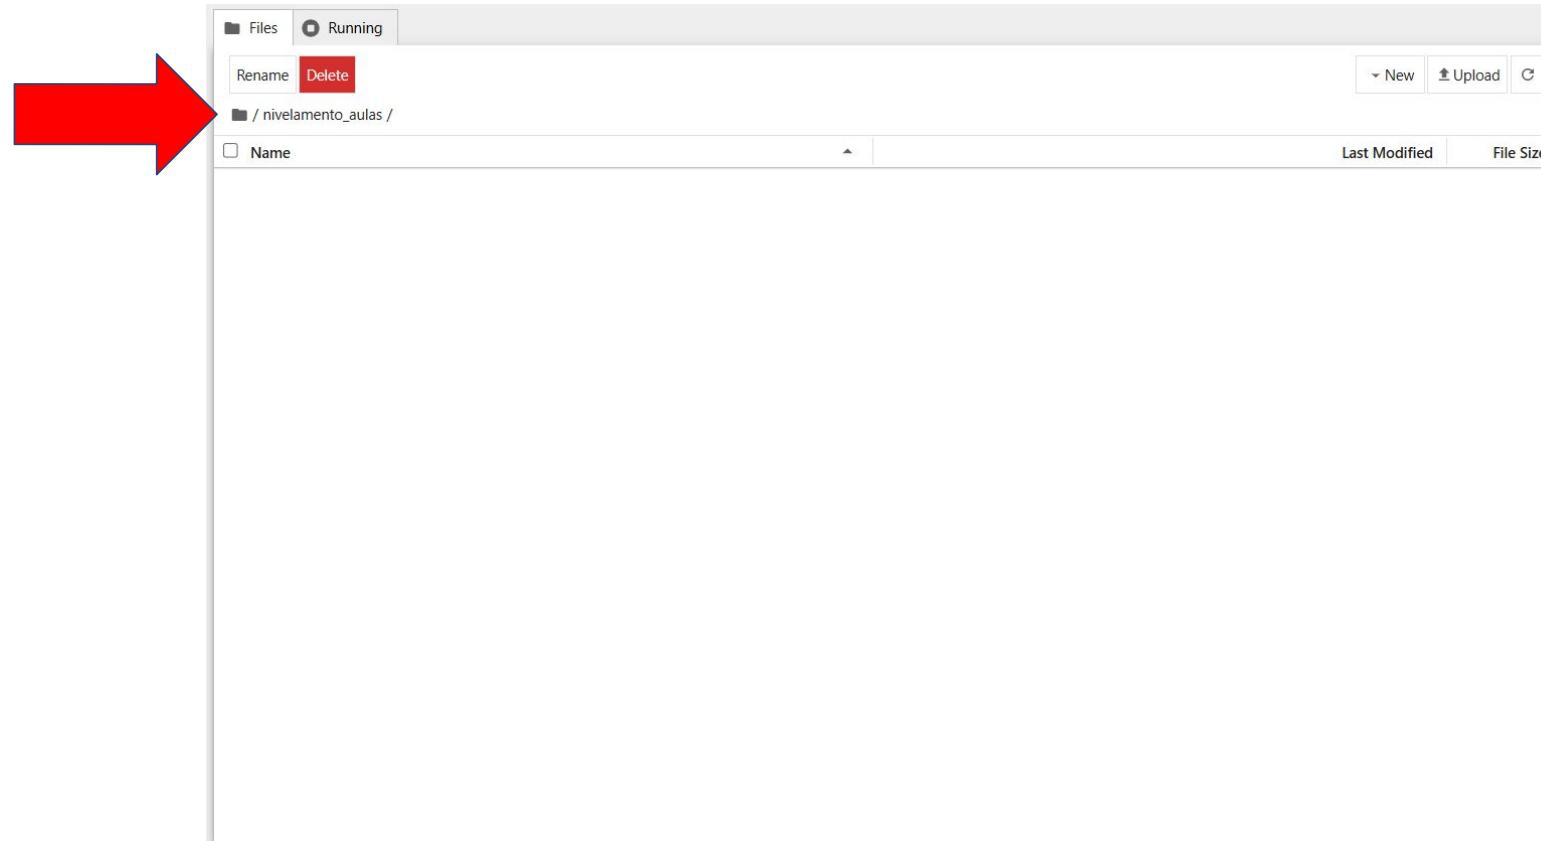
Name	Last Modified	File Size
Documents	9 days ago	
Downloads	14 minutes ago	
Favorites	3 years ago	
IDP	4 months ago	
intro_ml	4 months ago	
introducao_ao_ml	4 months ago	
Links	3 years ago	
local_cache	last year	
logs	last year	
Microsoft	last year	
miniconda3	12 months ago	
Music	3 years ago	
<b>nivelamento_aulas</b>	<b>1 minute ago</b>	
node_modules	5 months ago	
OneDrive	1 hour ago	
OneDrive - UEPB - Universidade Estadual da Paraíba	1 hour ago	
pasta2	10 months ago	
pinokio	last year	
Saved Games	last year	
Searches	6 months ago	
tensorflow_datasets	2 years ago	
testes	4 months ago	

# COMO USAR O JUPYTER NOTEBOOK?



Ela estará vazia, note que no canto superior esquerdo dá pra ver que estamos dentro da pasta.

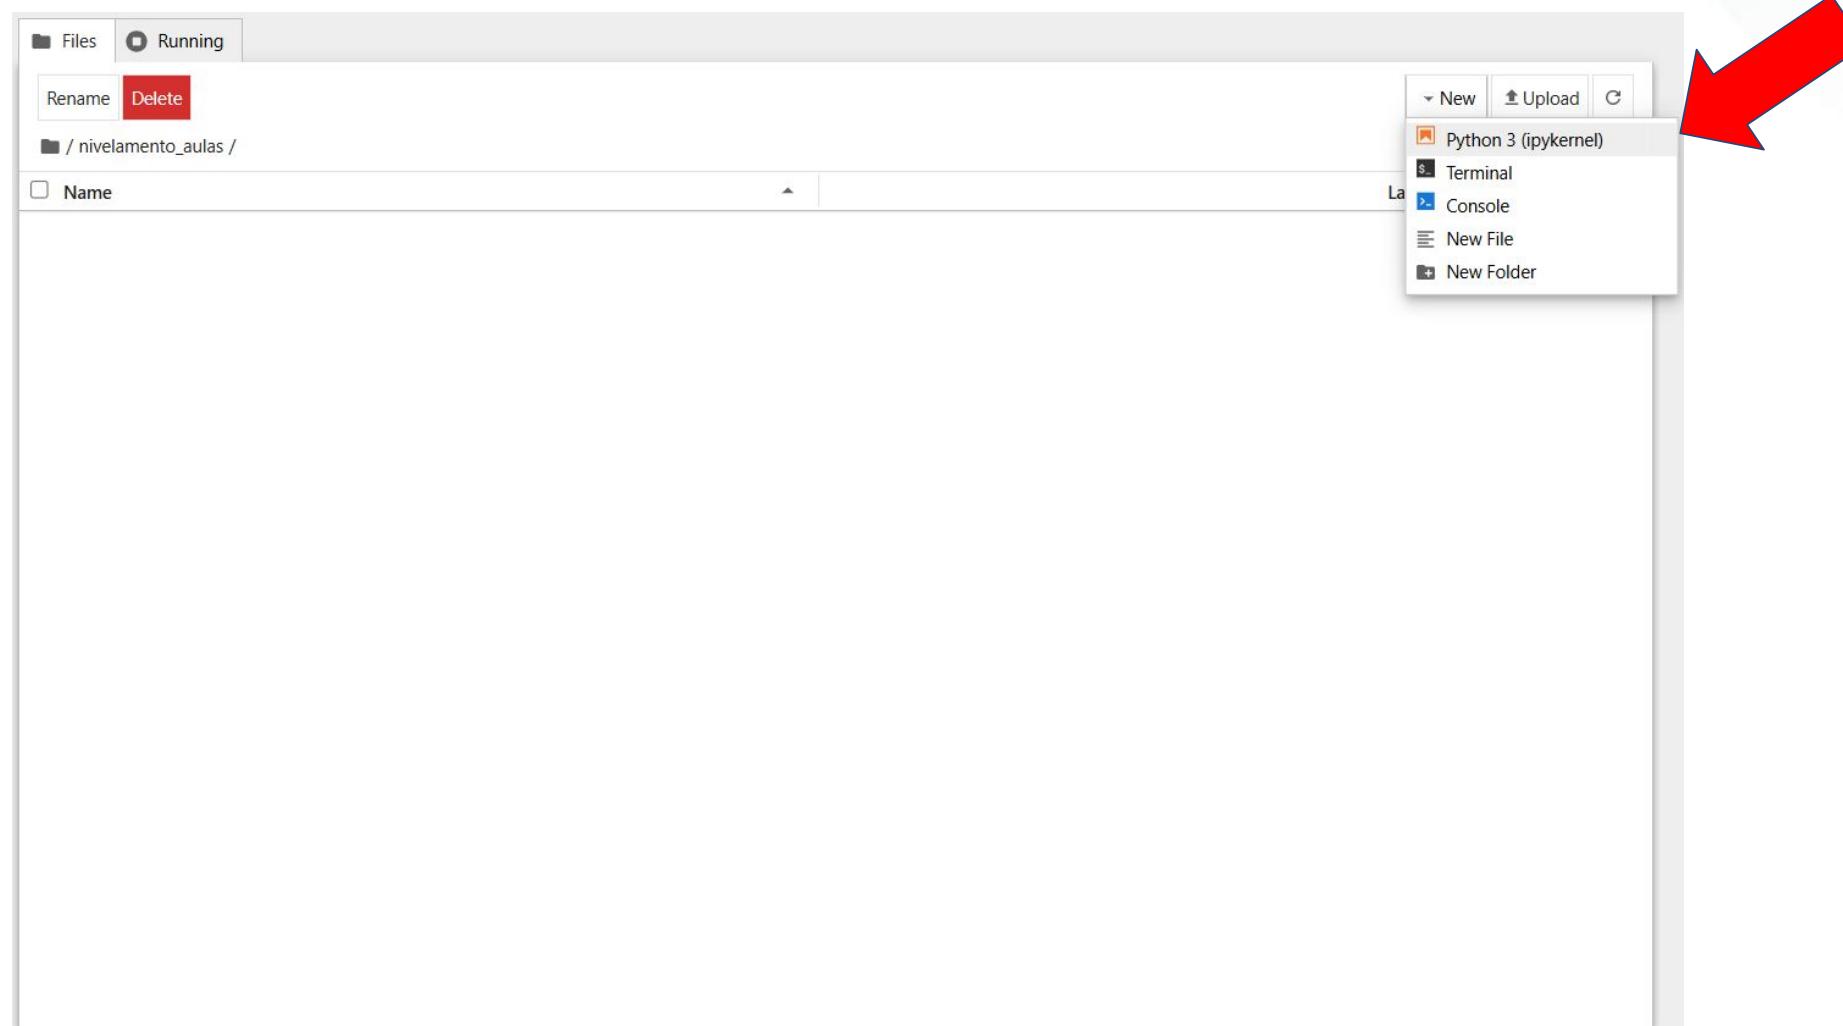
Caso queira voltar para a página inicial, clique no ícone da **pastinha** do lado do nome da pasta **nivelamento\_aulas**.



# COMO CRIAR UM ARQUIVO JUPYTER?



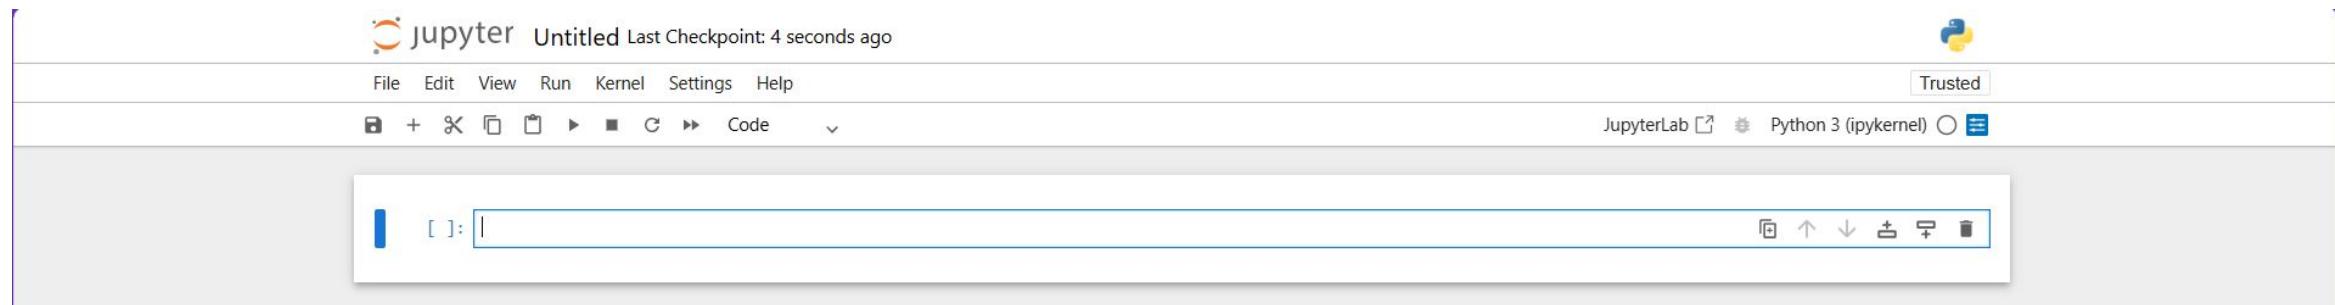
Agora clique em New novamente e depois em Python 3 (ipykernel)



# COMO CRIAR UM ARQUIVO JUPYTER?



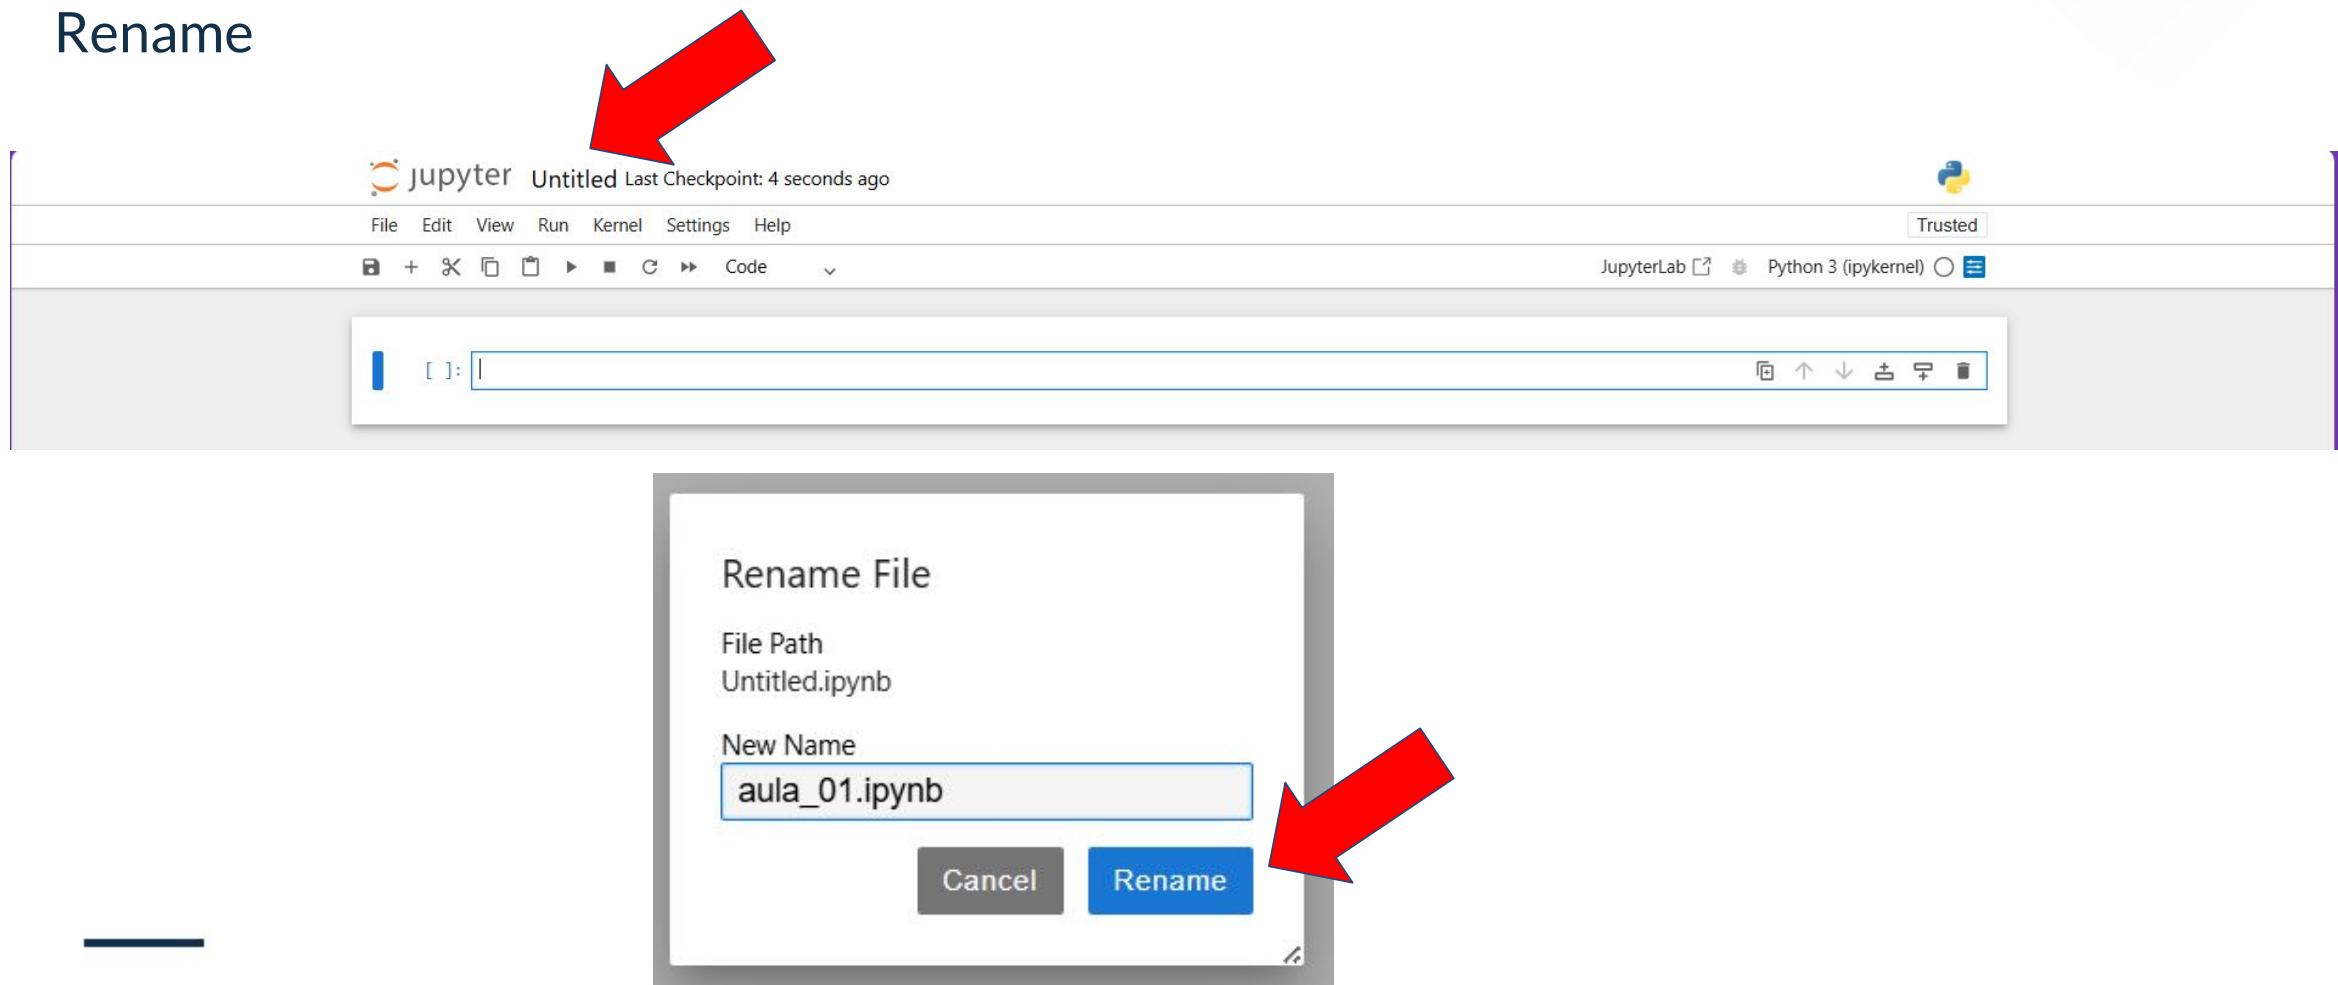
O jupyter notebook irá abrir outra aba contendo o modo editor.



# COMO CRIAR UM ARQUIVO JUPYTER?



Vamos renomear o arquivo para **aula\_01**, para isso clique no nome **Untitled**. Por fim clique em **Rename**



# COMO CRIAR UM ARQUIVO JUPYTER?



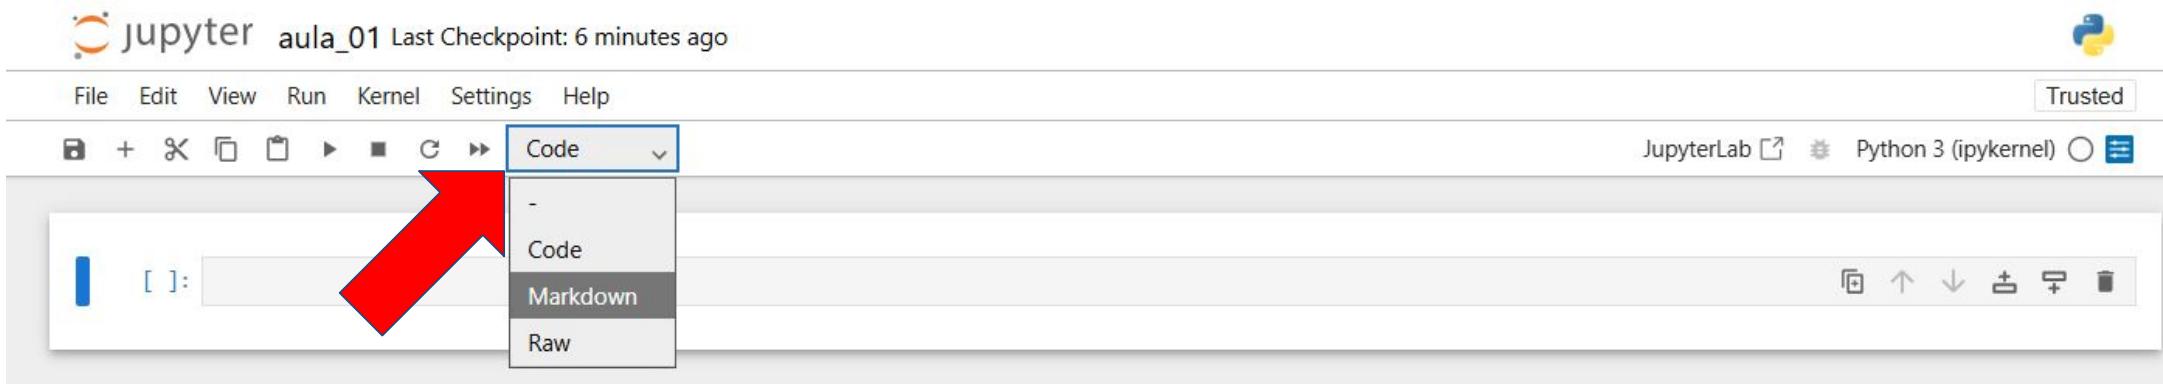
O jupyter notebook funciona no esquema de células, uma célula pode ser para escrever código ou escrever texto. **Células com o [ ]:** são para escrever código Python.



# COMO CRIAR UM ARQUIVO JUPYTER?



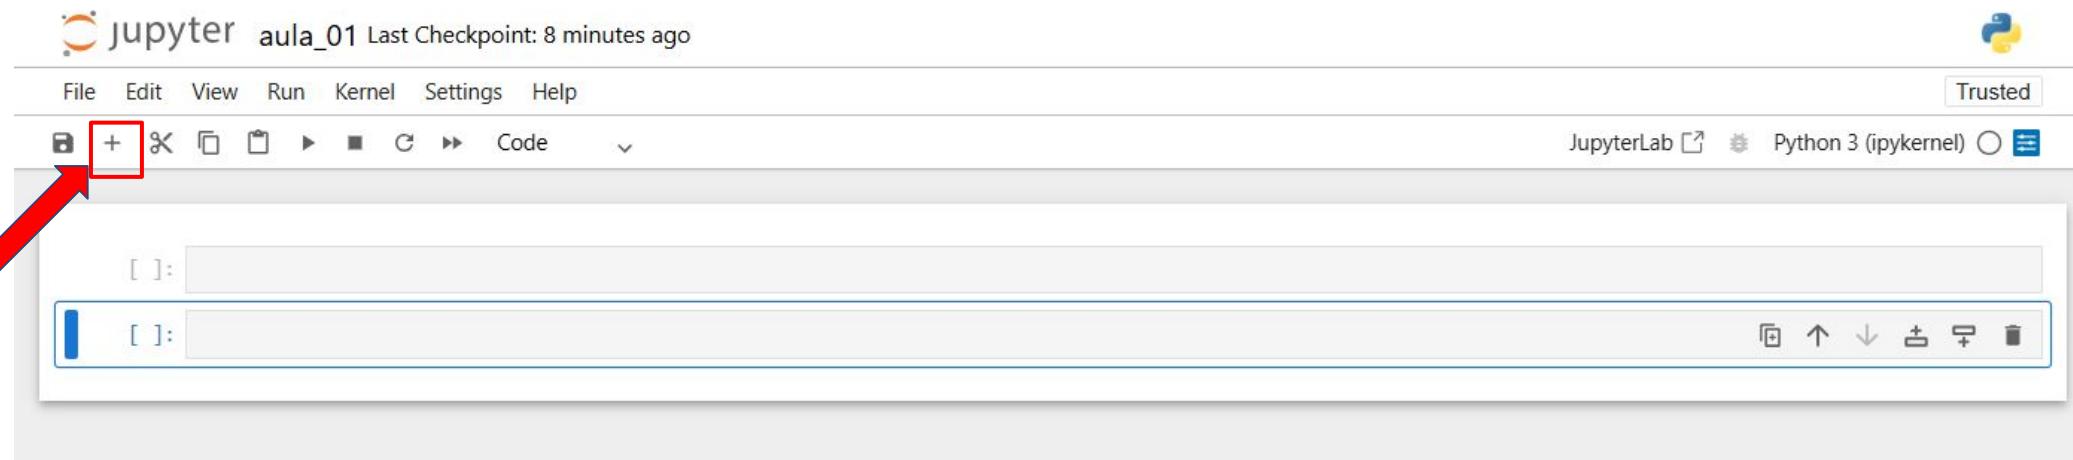
Para modificar o tipo da célula, basta ir em **Code** e depois **Markdown**.



# COMO CRIAR UM ARQUIVO JUPYTER?



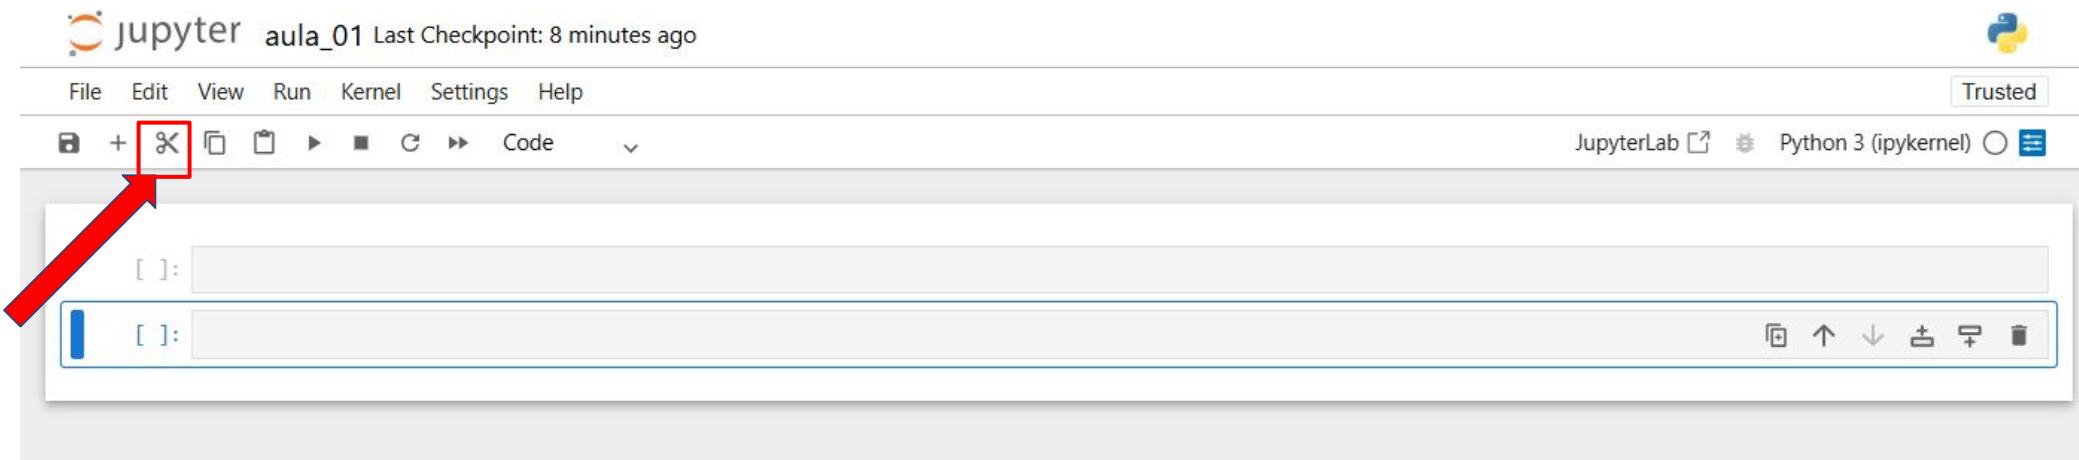
Para inserir uma nova célula, basta clicar no ícone de +.



# COMO CRIAR UM ARQUIVO JUPYTER?



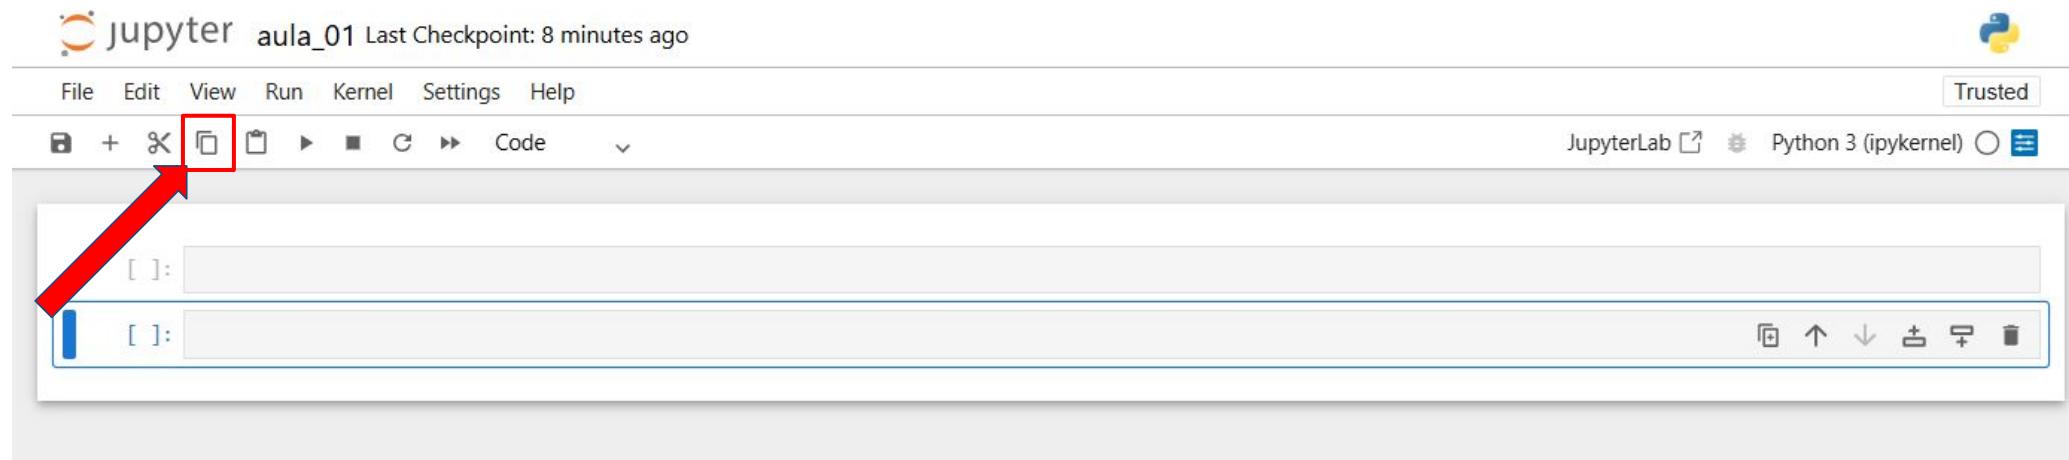
Para remover uma célula, basta clicar no ícone da tesoura.



# COMO CRIAR UM ARQUIVO JUPYTER?



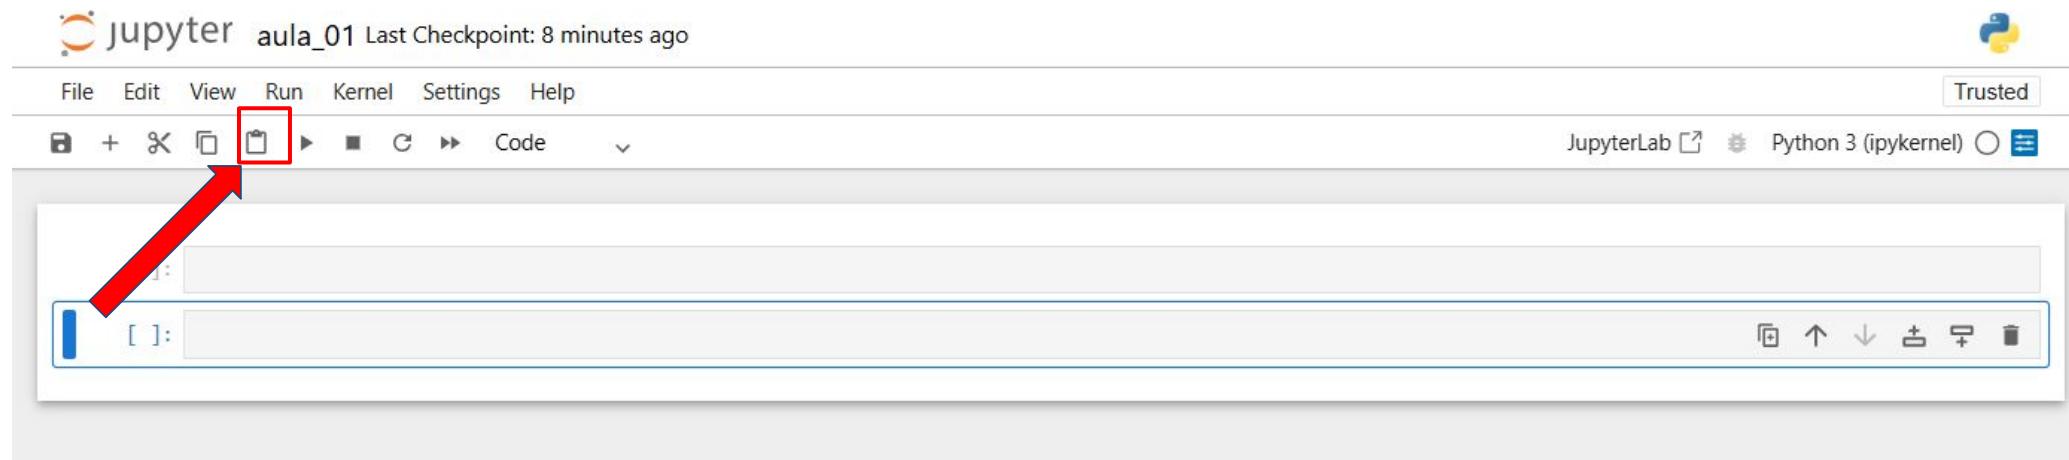
Para copiar uma célula, basta clicar no ícone dos papéis.



# COMO CRIAR UM ARQUIVO JUPYTER?



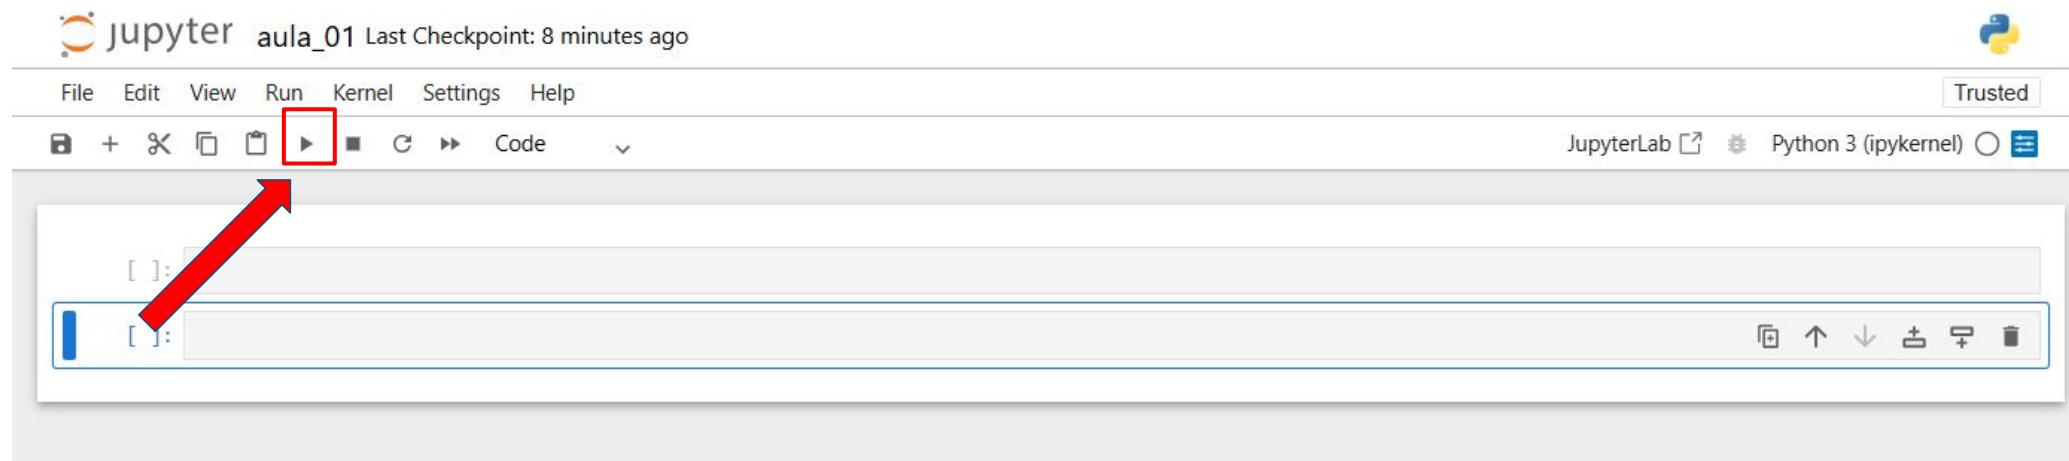
Para colar uma célula, basta clicar no ícone da prancheta.



# COMO CRIAR UM ARQUIVO JUPYTER?



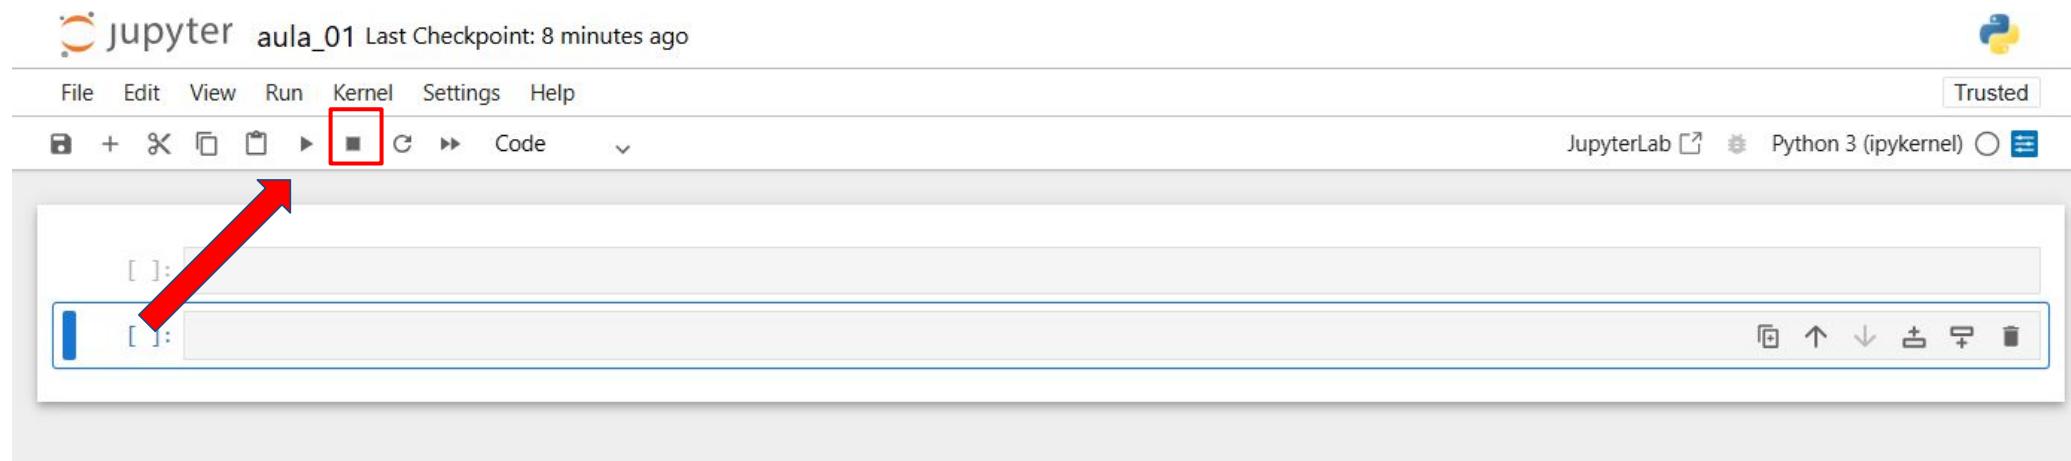
Você pode executar os comandos dentro de uma célula com a seta



# COMO CRIAR UM ARQUIVO JUPYTER?



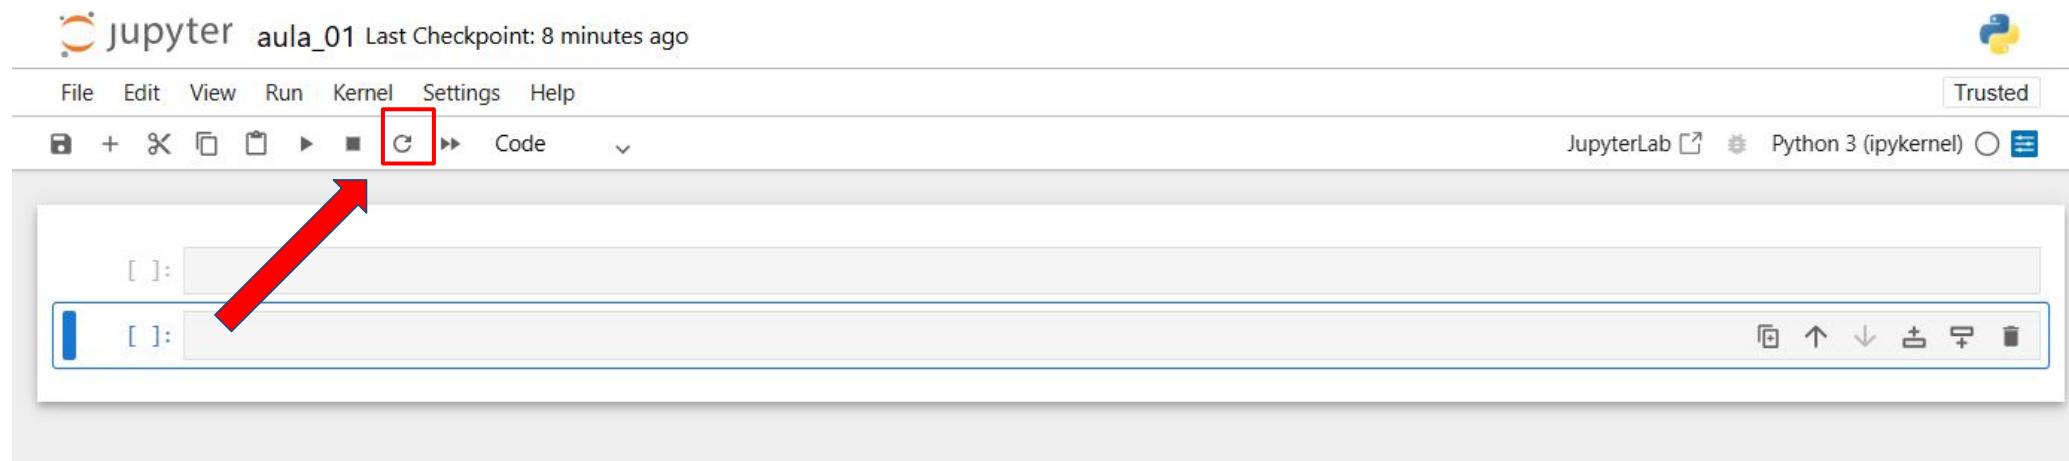
Você pode parar a execução de alguma célula com o ícone do quadradinho



# COMO CRIAR UM ARQUIVO JUPYTER?



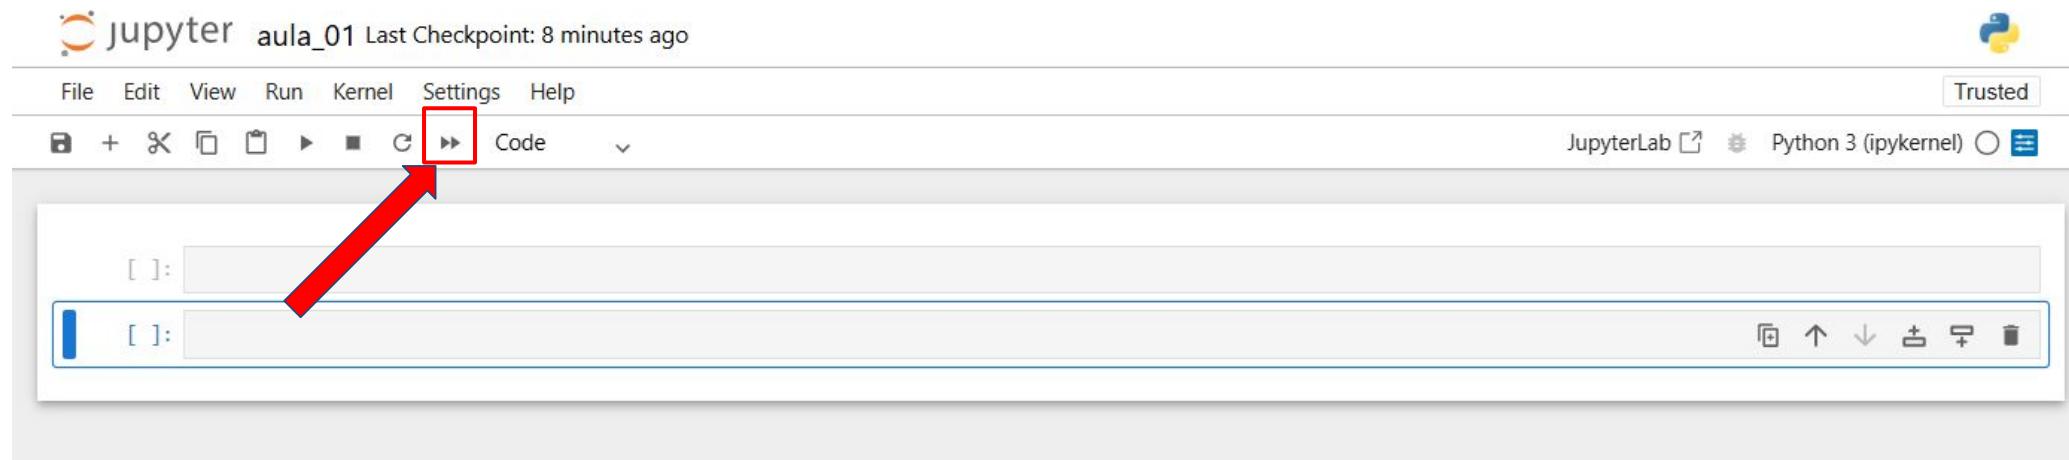
Para reiniciar todo o ambiente jupyter, basta clicar na seta circular



# COMO CRIAR UM ARQUIVO JUPYTER?



Para executar TODAS as células, basta clicar no ícone das duas setinhas.



# COMO CRIAR UM ARQUIVO JUPYTER?



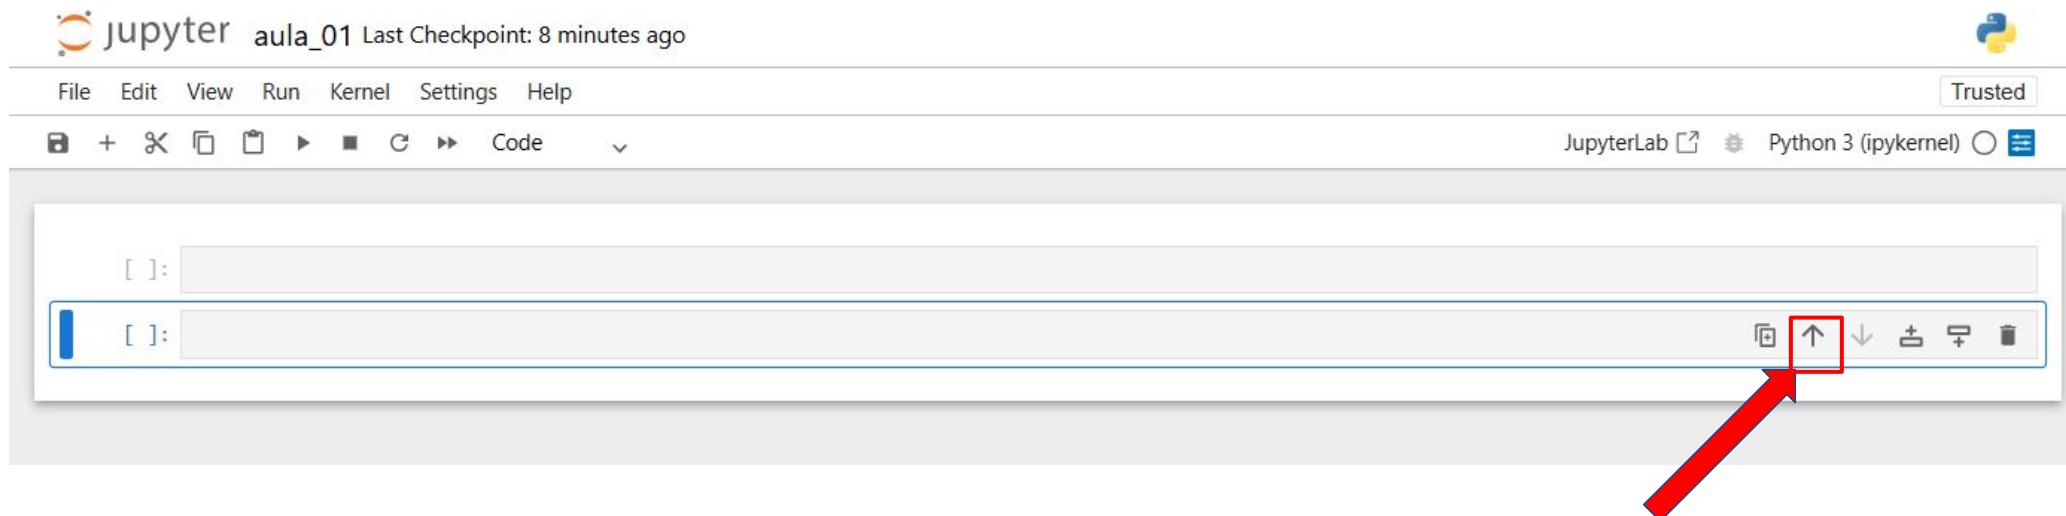
Use o comando ao lado da célula para duplicá-la.



# COMO CRIAR UM ARQUIVO JUPYTER?



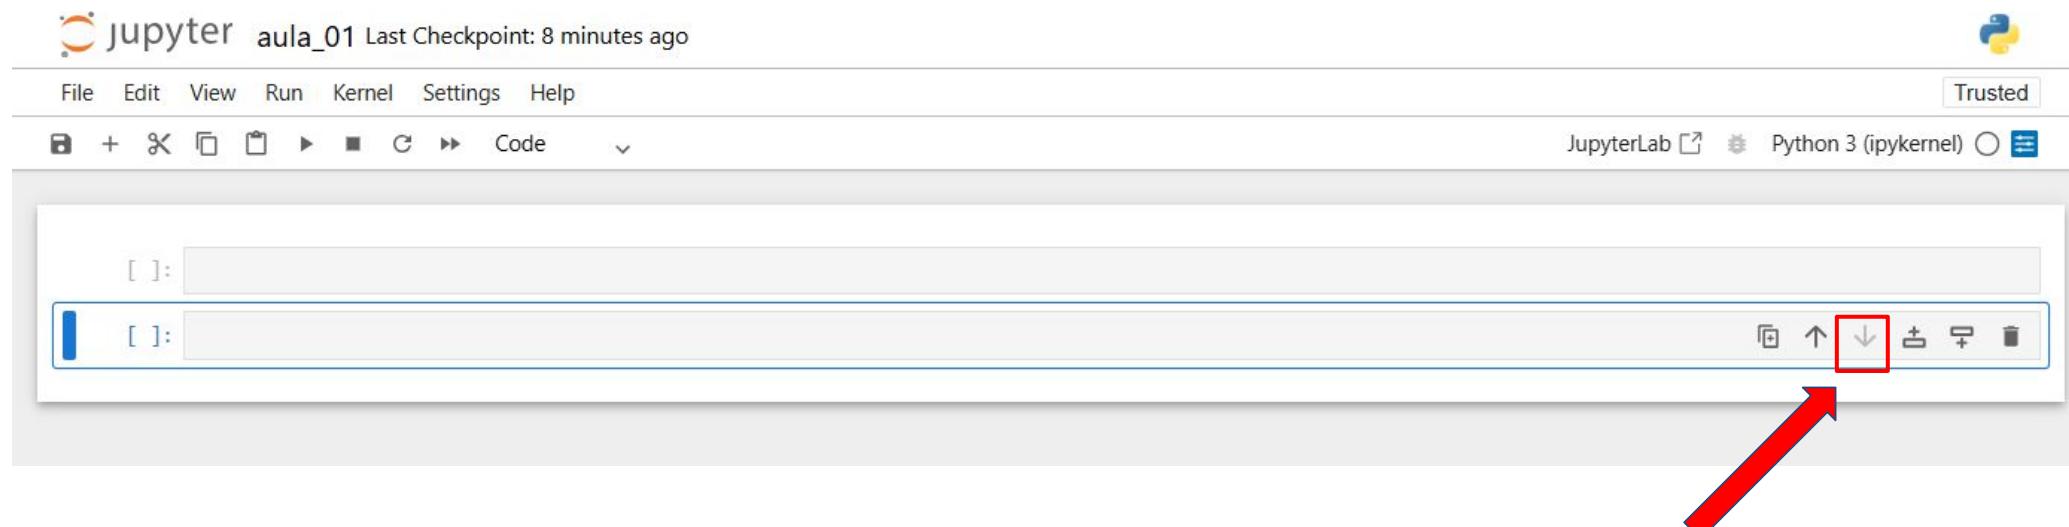
A seta pra cima serve para mudar sua posição deixando ela acima.



# COMO CRIAR UM ARQUIVO JUPYTER?



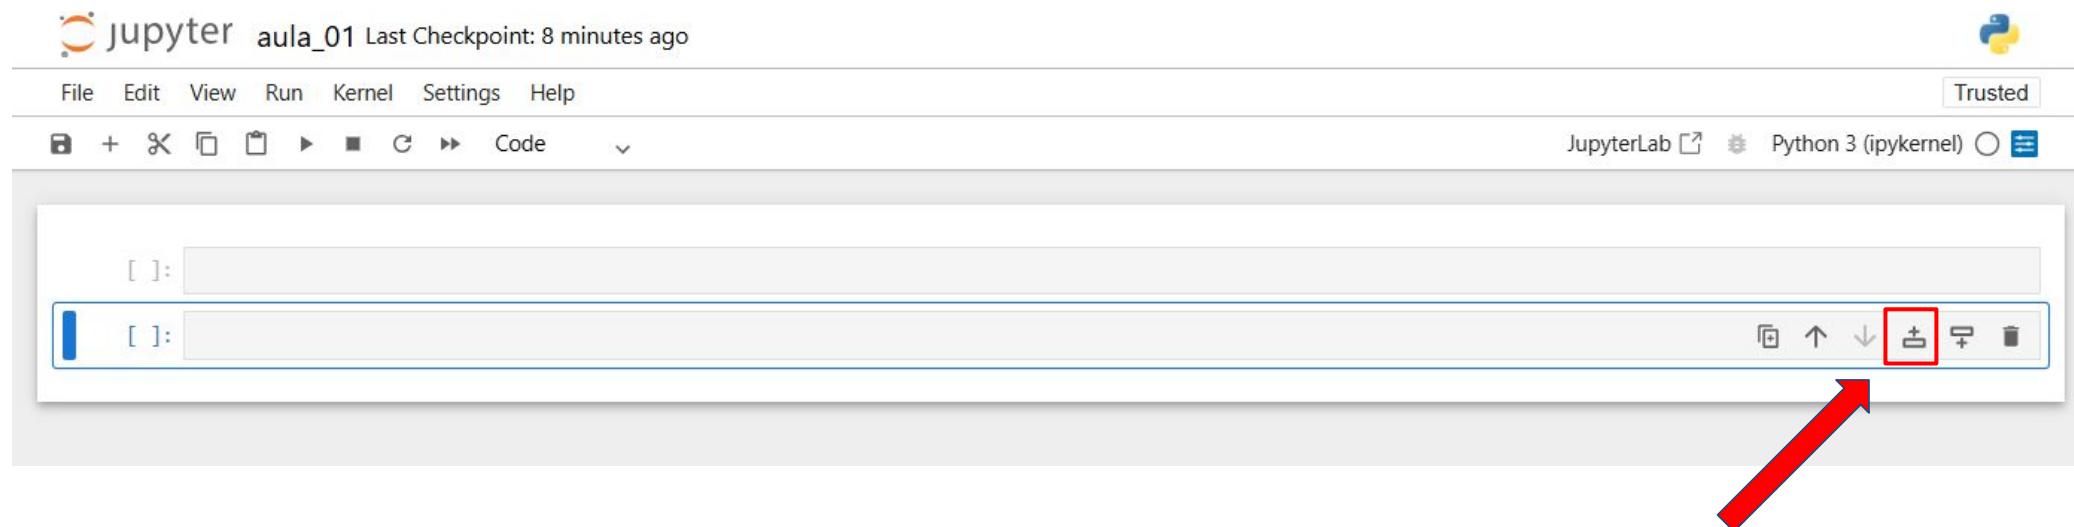
A seta pra baixo serve para mudar sua posição deixando ela embaixo.



# COMO CRIAR UM ARQUIVO JUPYTER?



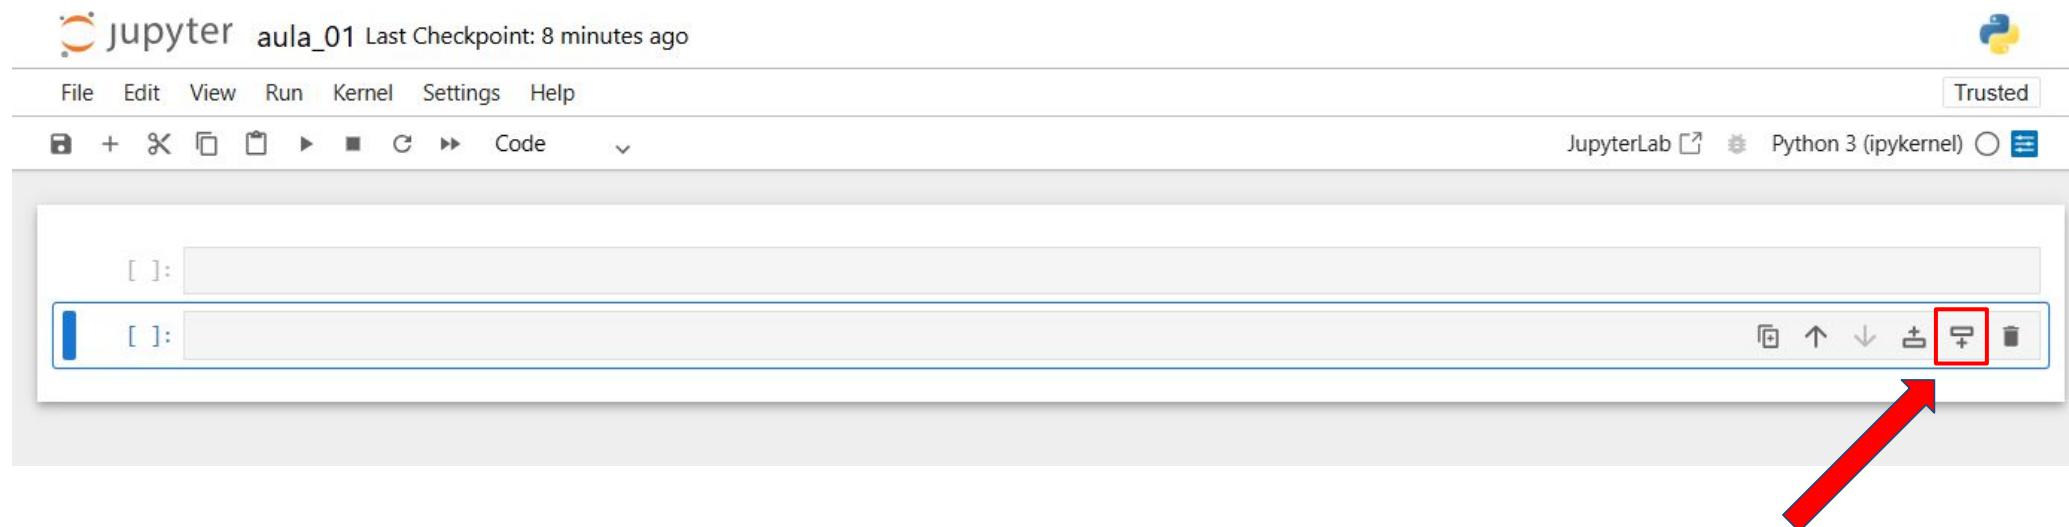
Esse comando serve para **criar uma célula acima**.



# COMO CRIAR UM ARQUIVO JUPYTER?



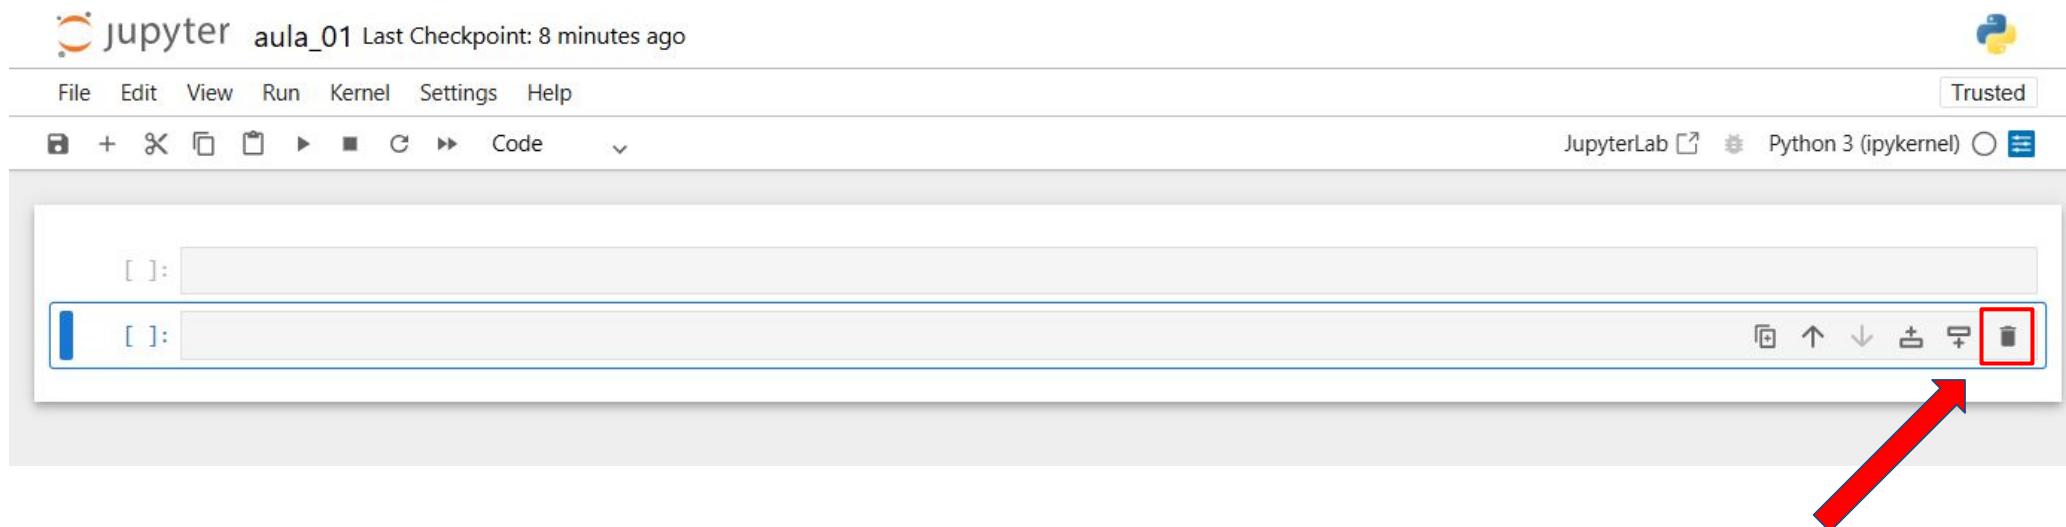
Esse comando serve para **criar uma célula** abaixo.



# COMO CRIAR UM ARQUIVO JUPYTER?



Esse comando serve para remover a célula atual.



# Introdução às Bibliotecas para ciência de dados

Como manipular dados no python

---

# RECAPITULANDO

- Na aula passada vimos a diferença entre editores de texto, IDEs e o ambiente jupyter notebook com o Anaconda, onde iremos utilizar a linguagem de programação python para realizar manipulações nos dados.
- Aprendemos como baixar, instalar o Anaconda, abrir o Jupyter notebook e manipular o python.

# RECAPITULANDO

Vimos que o Python possui uma enorme quantidade de bibliotecas para manipular os dados.



Disponível em: [20+ Python Libraries for Data Science Professionals \[2025 Edition\] – Quantum™ Ai Labs](#)

# O QUE É UMA BIBLIOTECA?

- Bibliotecas são coleções de módulos e funções pré-escritas que permitem aos desenvolvedores realizar tarefas complexas sem precisar escrever todo o código do zero.
  - Isto é, basicamente são um conjunto de códigos escritos por pessoas que servem para resolver algum problema específico.
  - O uso de bibliotecas promove a reutilização de código, o que acelera drasticamente o ciclo de desenvolvimento de qualquer projeto de software.
  - Ao utilizar soluções que já foram testadas e validadas por milhares de outros programadores, você minimiza a ocorrência de bugs e foca seus esforços apenas na lógica de negócio exclusiva da sua aplicação.
-

# O QUE É UMA BIBLIOTECA?

- Existem bibliotecas para quase todas as finalidades imagináveis, o que torna o Python uma linguagem extremamente versátil e poderosa no mercado atual.
  - Temos o Pandas para análise de dados, o Django para desenvolvimento web robusto e o Matplotlib para criação de gráficos, permitindo que o desenvolvedor transite entre diferentes áreas com facilidade.
  - A maioria das bibliotecas Python é de código aberto (Open Source), o que significa que são constantemente atualizadas e aprimoradas por uma comunidade global de desenvolvedores.
-

# BIBLIOTECA PARA CIÊNCIA DE DADOS

## Numpy



- O NumPy é a biblioteca fundamental para computação científica, servindo de base para quase todas as outras ferramentas de dados.
- É utilizado por debaixo dos panos na maioria das bibliotecas de ciência de dados como o pandas, matplotlib, seaborn, etc.
- Amplamente utilizado para operações aritméticas com matrizes e vetores.

Para mais informações, acesse: <https://numpy.org/>

---

# BIBLIOTECA PARA CIÊNCIA DE DADOS

Pandas



- Considerada a "planilha de Excel" dentro do código, o Pandas fornece estruturas chamadas DataFrames, que permitem ler, filtrar, limpar e transformar dados tabulares com facilidade.
- É a ferramenta essencial para o processo de ETL (Extração, Transformação e Carga), permitindo lidar com dados ausentes, agrupar informações complexas e importar arquivos em formatos como CSV, JSON ou SQL

Para mais informações, acesse:<https://pandas.pydata.org/>

---

# BIBLIOTECA PARA CIÊNCIA DE DADOS

Matplotlib e Seaborn



- Estas bibliotecas são responsáveis por transformar números em insights visuais através de gráficos.
- quanto o Matplotlib oferece controle total sobre cada detalhe do gráfico (como eixos e legendas), o Seaborn funciona como uma camada superior que facilita a criação de visualizações mais atraentes e complexas, como mapas de calor e gráficos de dispersão, com menos linhas de código.

Para mais informações, acesse:<https://matplotlib.org/> Ou <https://seaborn.pydata.org/>

# BIBLIOTECA PARA CIÊNCIA DE DADOS

## Scikit-Learn



- O Scikit-Learn é a biblioteca padrão ouro para aprendizado de máquina em Python, oferecendo ferramentas simples e eficientes para análise preditiva.
- Ela inclui algoritmos para classificação, regressão e agrupamento, além de funcionalidades para pré-processamento de dados e avaliação de modelos, permitindo que desenvolvedores criem modelos de Machine Learning sem precisar implementar manualmente cálculos estatísticos pesados.

Para mais informações, acesse: <https://scikit-learn.org/stable/index.html>

---

# Botando a Mão na Massa

Entendendo o problema de negócio

---

# ANTES DE COMEÇAR...

- Entendemos que o Python possui um ecossistema de bibliotecas que são códigos que foram criados por outras pessoas para lidarem com ciência de dados.
  - Mas antes de qualquer tipo de manipulação, é necessário saber qual o problema que você quer resolver.
  - Já que não adianta extrair informações de uma base de dados sem contexto algum.
-

# PROBLEMA INICIAL

## Contextualizando

- Recebemos uma base bruta do Banco Mundial com indicadores de 2019. Para realizar uma análise de viabilidade de investimentos, não precisamos de todas as colunas, nem de todos os países.
  - Precisamos reorganizar a base de dados para focar em nações que possuem perfis específicos e transformar dados técnicos em informações estratégicas para identificar líderes e lanternas globais em cada indicador.
-

# PROBLEMA INICIAL

## Perguntas a Serem Respondidas

- Como mostrar a base de dados dentro do ambiente de desenvolvimento?
  - Quantos países e quantas variáveis temos no nosso banco de dados?
  - Como calcular as estatísticas descritivas das variáveis?
-

# PROBLEMA INICIAL

## Perguntas a Serem Respondidas

- Como criar uma nova base de dados contendo apenas as colunas de riqueza e educação filtrando apenas países que possuem uma população superior a 100 milhões de habitantes?
  - Como extrair o valor exato do PIB per capita da 10<sup>a</sup> linha do DataFrame e, em seguida, selecionar as 5 primeiras linhas apenas para as colunas de terra arável e indústria?
-

# PROBLEMA INICIAL

## Perguntas a Serem Respondidas

- Como criar uma nova coluna que classifique como "Alta Escolaridade" países com Mão de Obra Qualificada acima de 50% e "Baixa Escolaridade" os demais?
  - Como podemos localizar o país que possui a maior Carga Industrial e aquele com a menor área de terra arável do mundo?
  - Quais países possuem uma porcentagem da força de trabalho com educação avançada superior a 25% e, simultaneamente, um gasto público em educação acima de 5% do PIB?
-

# PROBLEMA INICIAL

## Variáveis

- **NY.GDP.PCAP.CD (GDP\_PC)**: PIB per capita em dólares atuais. Representa a riqueza média produzida por cada habitante do país.
- **SL.TLF.ADVN.ZS (forca\_trab\_educ)**: Porcentagem da força de trabalho que possui educação avançada (nível superior ou pós-graduação).
- **AG.LND.ARBL.HA.PC (arable\_land)**: Hectares de terra arável (cultivável) disponíveis por pessoa na população.
- **NV.IND.TOTL.ZS (industria\_PERCPIB)**: Porcentagem do PIB que vem da indústria (incluindo mineração, manufatura, construção e serviços de utilidade pública).

# PROBLEMA INICIAL

## Variáveis

- **SE.XPD.TOTL.GD.ZS (gasto\_educ\_PERCPIB)**: Total de gastos públicos em educação expressos como uma porcentagem do PIB do país.
- **NE.GDI.FTOT.CD (FBKF)**: Formação Bruta de Capital Fixo. Mede o valor das aquisições de ativos fixos (máquinas, equipamentos e infraestrutura) em dólares.
- **SP.POP.TOTL (populacao)**: População total de residentes, independente do status legal, no meio do ano de 2019.

JÁ PODEMOS BOTAR A MÃO NA MASSA E COMEÇAR A ANALISAR OS DADOS? A RESPOSTA É NÃO!  
PRECISAMOS CRIAR UM DICIONÁRIO DE DADOS!

---

# PROBLEMA INICIAL

## Dicionário de Dados

- **O que é um Dicionário de Dados?** É um documento centralizado que contém os metadados sobre o seu conjunto de dados.
- Imagine-o como um manual de instruções que explica detalhadamente o que cada coluna representa, garantindo que qualquer pessoa entenda exatamente o que está sendo processado

# PROBLEMA INICIAL

## Dicionário de Dados

- **Por que criar um dicionário antes de codar?** A criação do dicionário é o passo que separa um "curioso de dados" de um "Cientista de Dados".
- Ele serve para evitar conclusões erradas (ex: confundir dólar com real), padronizar o entendimento entre os membros da equipe e facilitar a escolha dos tipos de dados corretos no Pandas (inteiros, decimais ou textos).

# PROBLEMA INICIAL

## Dicionário de Dados

Como criar o dicionário na prática? Para construir um dicionário robusto, estruturamos uma tabela com 5 pilares fundamentais:

- **Nome:** O nome exato da coluna.
  - **Descrição:** O significado funcional daquela informação.
  - **Tipo de Dado:** De acordo com a classificação estatística (Qualitativa nominal, ordinal, quantitativa discreta ou contínua)
  - **Unidade de Medida:** Crucial para saber se falamos de USD, %, ou anos.
  - **Valores Válidos:** O intervalo esperado (ex: 0 a 100 para taxas) ou categorias (ex: Infecciosa/Não-Transmissível).
-

# PROBLEMA INICIAL

## Classificação Estatística de Dados

**Dados Quantitativos** São variáveis que expressam quantidades e podem ser medidas em uma escala numérica.

- **Discretas**, que representam contagens de números inteiros (ex: número de médicos, número de leitos)
- **Contínuas**, que podem assumir qualquer valor em um intervalo, geralmente com casas decimais

# PROBLEMA INICIAL

## Classificação Estatística de Dados

**Dados Qualitativos (Categóricos)** São variáveis que expressam atributos, qualidades ou categorias, não possuindo um valor numérico intrínseco.

- **Nominais**, onde não existe uma ordem entre as categorias (ex: Nome da Doença, Gênero, Tipo de Tratamento)
- **Ordinais**, onde existe uma hierarquia lógica (ex: Faixa Etária, Nível de Escolaridade)



# PROBLEMA INICIAL

Considere o exemplo abaixo

O CEP é uma variável quantitativa ou qualitativa?

- Resposta: Qualitativa nominal, já que não faz sentido realizar operações aritméticas com o CEP.

A idade uma variável discreta ou contínua?

- Resposta: Depende! Posso considerar discreta ou contínua dependendo do meu contexto de negócio.

# PROBLEMA INICIAL

E variáveis de data?

**Na estatística, data é simplesmente data!**

- Ela parece se comportar com uma variável quantitativa pois conseguirmos calcular um intervalo entre datas, mas parece ter uma ordem cronológica. Porém também há a característica de ser cíclica.

**Vamos praticar!**

---

# PROBLEMA INICIAL

O Custo do Tratamento "Ao abrir a planilha de custos de uma cirurgia cardíaca, você encontra o valor de \$ 15.450,75. **Como você classificaria a variável?**

- **Quantitativa Contínua.** Por que? O valor possui centavos (casas decimais).  
O dinheiro é uma grandeza que pode ser medida em qualquer fração dentro de um intervalo.

# PROBLEMA INICIAL

Capacidade da UTI "O diretor do hospital informa que a unidade possui exatamente 42 leitos disponíveis no momento. **Como você classificaria a variável?**

- **Quantitativa Discreta.** Por que? Representa uma contagem de unidades inteiras. Não existe "meio leito" físico na gestão hospitalar.

# PROBLEMA INICIAL

O Estágio da Doença "No prontuário, a gravidade da condição do paciente está marcada como 'Moderada' (em uma escala de Leve, Moderada e Grave). **Como você classificaria a variável?**

- **Qualitativa Ordinal.** Por que? É um atributo (texto), mas que possui uma hierarquia e ordem lógica clara de intensidade.

# PROBLEMA INICIAL

Identificação Regional "Para mapear a origem das infecções, o analista usa o código 70000-000 (CEP) para agrupar os casos. **Como você classificaria a variável?**

- **Qualitativa Nominal.** Por que? Apesar de ser formado por algarismos, ele serve apenas como um rótulo de localização. Não faz sentido somar dois CEPs ou tirar a média deles.

# VAMOS A OBRA!

Criando o diretório, executando o Jupyter e desenvolvendo código

---

# RECAPITULANDO

- Na aula passada, vimos a importância da estrutura do DataFrame e das Series.
- Aprendemos que o Pandas não organiza os dados apenas em tabelas visuais, mas em estruturas indexadas onde cada coluna (Series) possui um tipo de dado específico que dita o que podemos fazer com ela.

# RECAPITULANDO

- Entendemos que identificar se um dado é uma variável quantitativa ou qualitativa é o primeiro passo para não cometer erros básicos, como tentar somar colunas de texto ou agrupar dados por valores contínuos sem critério.
  - Comprendemos que, enquanto o loc nos dá a liberdade de filtrar por nomes de países ou estados (como as UFs da RAIS), o iloc é a nossa ferramenta de precisão cirúrgica para fatiar o DataFrame ou extrair amostras específicas.
-

# Problemática

- Você recebeu o arquivo `rais_mulheres_2008.xlsx`, que é uma amostra riquíssima do mercado formal.
- No entanto, ela não contém dados macroeconômicos. Para uma análise completa, você precisa saber também o PIB per capita dos estados.
- O problema: Os dados do PIB estão em um DataFrame pequeno de 27 linhas (`df_pib_pc`), enquanto a RAIS tem milhares de linhas. Se você tentar copiar e colar, o erro é certo.

O QUE DEVEMOS FAZER AGORA?

---

# Dicionário de dados da RAIS

Nome da Coluna	Descrição Funcional	Tipo de Dado	Unidade de Medida	Valores Válidos
<code>uf</code>	Sigla da Unidade da Federação (Chave da RAIS).	Qualitativa Nominal	Texto (Sigla)	AC, AL, ..., TO
<code>UF</code>	Sigla da Unidade da Federação (Chave do PIB).	Qualitativa Nominal	Texto (Sigla)	AC, AL, ..., TO
<code>salario</code>	Remuneração nominal da trabalhadora.	Quantitativa Contínua	Real (R\$)	Valor > 0
<code>PIB_PC</code>	Riqueza média por habitante do estado em 2008.	Quantitativa Contínua	Real (R\$)	Valor > 0
<code>escolaridade</code>	Grau de instrução formal da trabalhadora.	Qualitativa Ordinal	Categoria	SUP. COMP, SUP. INCOMP, MEDIO COMPL, MEDIO INCOMP, FUND COMPL, 6. A 9. FUND, 5.A CO FUND, ATE 5.A INC

# Dicionário de dados PIB

Nome da Coluna	Descrição Funcional	Tipo de Dado	Unidade de Medida	Valores Válidos
UF	Sigla da Unidade da Federação.	Qualitativa Nominal	Texto (Sigla)	SP, MG, RJ, DF, etc.
PIB_PC	Produto Interno Bruto per capita da UF em 2008.	Quantitativa Contínua	Real (R\$)	5.372 a 45.977

# JOINS

- Um join é simplesmente uma forma de juntar duas tabelas usando algo que elas têm em comum. Note que:

BASE RAIS

Nome	UF	Escolaridade	Salário
Ana	SP	SUP. COMP	4.500
Beatriz	CE	MEDIO COMPL	2.100
Carla	SP	MEDIO COMPL	2.800
Daniela	DF	SUP. COMP	6.200
Elisa	MG	MEDIO INCOMP	1.900
Fernanda	XX	FUND COMPL	1.500

BASE PIB

UF	PIB_PC
CE	7.111
DF	45.977
SP	24.456
RJ	22.500
BA	8.900

# JOINS

- O que tem em comum em ambas as tabelas?

**BASE RAIS**

Nome	UF	Escolaridade	Salário
Ana	SP	SUP. COMP	4.500
Beatriz	CE	MEDIO COMPL	2.100
Carla	SP	MEDIO COMPL	2.800
Daniela	DF	SUP. COMP	6.200
Elisa	MG	MEDIO INCOMP	1.900
Fernanda	XX	FUND COMPL	1.500

**BASE PIB**

UF	PIB_PC
CE	7.111
DF	45.977
SP	24.456
RJ	22.500
BA	8.900

# JOINS

- Note que o que desejo é que a **BASE RAIS** contenha a informação da **BASE PIB**, portanto preciso fazer o **left join**!

BASE RAIS			
Nome	UF	Escolaridade	Salário
Ana	SP	SUP. COMP	4.500
Beatriz	CE	MEDIO COMPL	2.100
Carla	SP	MEDIO COMPL	2.800
Daniela	DF	SUP. COMP	6.200
Elisa	MG	MEDIO INCOMP	1.900
Fernanda	XX	FUND COMPL	1.500

LEFT JOIN



BASE PIB	
UF	PIB_PC
CE	7.111
DF	45.977
SP	24.456
RJ	22.500
BA	8.900

Nome	UF	Escolaridade	Salário	PIB_PC
Ana	SP	SUP. COMP	4.500	24.456
Beatriz	CE	MEDIO COMPL	2.100	7.111
Carla	SP	MEDIO COMPL	2.800	24.456
Daniela	DF	SUP. COMP	6.200	45.977
Elisa	MG	MEDIO INCOMP	1.900	NULL
Fernanda	XX	FUND COMPL	1.500	NULL

# JOINS

- E se quiséssemos apenas o que tem em comum em cada base de dados? Usaríamos o **inner join**?

BASE RAIS			
Nome	UF	Escolaridade	Salário
Ana	SP	SUP. COMP	4.500
Beatriz	CE	MEDIO COMPL	2.100
Carla	SP	MEDIO COMPL	2.800
Daniela	DF	SUP. COMP	6.200
Elisa	MG	MEDIO INCOMP	1.900
Fernanda	XX	FUND COMPL	1.500

INNER JOIN  
→

BASE PIB	
UF	PIB_PC
CE	7.111
DF	45.977
SP	24.456
RJ	22.500
BA	8.900

Nome	UF	Escolaridade	Salário	PIB_PC
Ana	SP	SUP. COMP	4.500	24.456
Carla	SP	MEDIO COMPL	2.800	24.456
Beatriz	CE	MEDIO COMPL	2.100	7.111
Daniela	DF	SUP. COMP	6.200	45.977

# JOINS

- E se quiséssemos que a BASE PIB contenha as informações da BASE RAIS? Nesse caso usaremos o **right join**!

BASE RAIS				
Nome	UF	Escolaridade	Salário	
Ana	SP	SUP. COMP	4.500	
Beatriz	CE	MEDIO COMPL	2.100	
Carla	SP	MEDIO COMPL	2.800	
Daniela	DF	SUP. COMP	6.200	
Elisa	MG	MEDIO INCOMP	1.900	
Fernanda	XX	FUND COMPL	1.500	

RIGHT JOIN  
→

BASE PIB	
UF	PIB_PC
CE	7.111
DF	45.977
SP	24.456
RJ	22.500
BA	8.900

Nome	UF	Escolaridade	Salário	PIB_PC
Ana	SP	SUP. COMP	4.500	24.456
Carla	SP	MEDIO COMPL	2.800	24.456
Beatriz	CE	MEDIO COMPL	2.100	7.111
Daniela	DF	SUP. COMP	6.200	45.977
NULL	RJ	NULL	NULL	22.500
NULL	BA	NULL	NULL	8.900

# JOINS

- E se quiséssemos juntar tudo de informação? Nesse caso usaremos o **outer join**!

BASE RAIS			
Nome	UF	Escolaridade	Salário
Ana	SP	SUP. COMP	4.500
Beatriz	CE	MEDIO COMPL	2.100
Carla	SP	MEDIO COMPL	2.800
Daniela	DF	SUP. COMP	6.200
Elisa	MG	MEDIO INCOMP	1.900
Fernanda	XX	FUND COMPL	1.500

OUTER JOIN



BASE PIB	
UF	PIB_PC
CE	7.111
DF	45.977
SP	24.456
RJ	22.500
BA	8.900

Nome	UF	Escolaridade	Salário	PIB_PC
Ana	SP	SUP. COMP	4.500	24.456
Carla	SP	MEDIO COMPL	2.800	24.456
Beatriz	CE	MEDIO COMPL	2.100	7.111
Daniela	DF	SUP. COMP	6.200	45.977
Elisa	MG	MEDIO INCOMP	1.900	NULL
Fernanda	XX	FUND COMPL	1.500	NULL
NULL	RJ	NULL	NULL	22.500
NULL	BA	NULL	NULL	8.900

# Problemática

Agora podemos analisar os dados para responder as seguintes perguntas:

- Como podemos descobrir quantas trabalhadoras existem por Unidade Federativa (UF) na nossa amostra e qual a porcentagem que cada estado representa em relação ao total do país?
  - Crie um DataFrame chamado `df amostra` contendo apenas 5 mulheres selecionadas aleatoriamente.
-

# Problemática

- Crie um DataFrame chamado df amostra contendo apenas 5 mulheres selecionadas aleatoriamente.
  - Se tentarmos unir essa amostra de 5 pessoas com a base de PIB (que tem 27 estados), qual comportamento você espera observar ao testar:
    - **Left Join:** Veremos as 5 mulheres com seus PIBs ou os 27 estados com PIBs vazios?
    - **Right Join:** O que acontece com os estados que não possuem nenhuma representante nessas 5 mulheres selecionadas?

# VAMOS A OBRA!

Criando o diretório, executando o Jupyter e desenvolvendo código

---

# O Problema do Banco Mundial

Até agora, conseguimos identificar o PIB de um país específico ou listar os 5 mais ricos. Mas, para um gestor global, restam perguntas que os dados brutos, sozinhos, não respondem de forma clara.

- E se quiséssemos saber qual a população total em cada um dos quintis de riqueza?
  - E se quiséssemos saber qual é o investimento médio em educação comparando por quintis?
  - Qual o investimento mínimo, máximo, a mediana e a média comparando por quintis?
-

# A Resposta: Agregação de Dados

- Para responder a essas perguntas, não olhamos mais para o "País A" ou "País B", mas sim para o Grupo. É aqui que entra a Agregação:
  - Agregar é o ato de "resumir" a informação. Em vez de termos 200 linhas de países, passamos a ter apenas 5 linhas (uma para cada quintil: pobres, médio pobres, médio, médio ricos e ricos).
-

# A Resposta: Agregação de Dados

Por que isso é valioso?

- **Expressividade:** Com apenas uma linha de código, transformamos microdados dispersos em inteligência estratégica.
  - **Visão Macro:** Conseguimos enxergar padrões que estão ocultos quando olhamos os dados linha por linha.
-

# A Resposta: Agregação de Dados

Suponhamos que queremos saber quantas vendas cada cidade fez:

cidade	produto	vendas	quantidade
Recife	A	100	10
Recife	B	150	15
Salvador	A	200	20
Salvador	B	120	12
Fortaleza	A	180	18
Fortaleza	B	160	16

# A Resposta: Agregação de Dados

Podemos agrupar cada venda da cidade com base na soma:

cidade	produto	vendas	quantidade
Recife	A	100	10
Recife	B	150	15
Salvador	A	200	20
Salvador	B	120	12
Fortaleza	A	180	18
Fortaleza	B	160	16



cidade	total_vendas
Fortaleza	340
Recife	250
Salvador	320

# VAMOS A OBRA!

Criando o diretório, executando o Jupyter e desenvolvendo código

---

# Agora é com vocês!

Usando a base de dados `rais_mulheres_2008.xlsx`. Resolva abaixo:

- Exiba as estatísticas descritivas (média, desvio padrão, quartis) da coluna de salário.
  - Filtre o DataFrame para exibir apenas as trabalhadoras com Ensino Superior Completo (SUP. COMP).
  - Conte quantas trabalhadoras existem em cada UF.
  - Crie uma nova coluna chamada `salario_anual` que seja o valor do salário multiplicado por 12.
  - Realize um Inner Join entre `df rais` e `df_pib_pc` para anexar o PIB de cada estado às trabalhadoras. Nomeie essa base de `base_faixa`.
-

# Agora é com vocês!

- Na base\_faixa, crie uma coluna chamada faixa\_pib que divida os valores de PIB\_PC em 3 categorias (Baixo, Médio, Alto) usando quantis.
- Crie uma amostra aleatória de 10 mulheres e realize um Right Join com a tabela de PIB. Observe o que acontece com os estados que não possuem representantes na amostra.
- Agrupe os dados da base\_faixa pela coluna escolaridade e calcule a média e a mediana dos salários.
- Agrupe os dados da base\_faixa pela nova coluna faixa\_pib e calcule a soma total da remuneração e a contagem de trabalhadoras por grupo.
- Faça um agrupamento múltiplo: calcule a média salarial cruzando faixa\_pib e escolaridade simultaneamente na base\_faixa.

**Dúvidas?**

Obrigado pela atenção!

---

**Mateus Rocha**

Cientista de Dados | Estatístico